

武汉大学

本科毕业论文（设计）

投资者预期共识定价效应研究——
基于多 Agent 视角

姓 名：齐悦然
学 号：2022301051279
专 业：金融学
学 院：经济与管理学院
指导教师：李斌 教授

二〇二六年三月

原创性声明

本人郑重声明：所呈交的论文（设计），是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文（设计）不包含任何其他个人或集体已发表及撰写的研究成果。对本论文（设计）做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文（设计）工作过程中没有伪造数据等行为。若在本论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：

指导教师签名：

日 期：

年 月 日

版权使用授权书

本人完全了解武汉大学有权保留并向有关部门或机构送交本论文（设计）的复印件和电子版，允许本论文（设计）被查阅和借阅。本人授权武汉大学将本论文的全部或部分内容编入有关数据进行检索和传播，可以采用影印、缩印或扫描等复制手段保存和汇编本论文（设计）。

作者签名：

指导教师签名：

日 期：

年 月 日

摘 要

随着人工智能技术快速发展，投资者能够以更精确的方式处理信息，形成交易决策。投资者在特定资产上达成预期共识，能否影响资产价格，这一问题对于理解金融市场的运行规律和稳定性有着重要的意义。本文通过构建多个 Agent 投资者，以 88 个因子数据作为输入，MLP 模型作为 Agent 的决策模型，通过强化学习训练方式，探究了 Agent 投资者的预期共识定价效应。实验的结果表明，投资者的预期共识度越高，股票的未来收益越高，这一结论在一系列稳健性检验后依然成立。进一步的，本文从融资和融券约束的角度，探讨了预期共识定价效应的形成机制。实验的结果表明，融资和融券约束是预期共识定价效应的重要形成机制，在放松融资和融券约束后，预期共识定价效应显著减弱。最后，本文从企业市值、股权异质性和市场周期的角度，分析了预期共识定价效应的异质性。实验的结果表明，小市值企业、非国企企业和牛市周期中的企业，其预期共识定价效应显著更高。最后，本文根据研究结论，提出了相应的政策建议和研究展望。

关键词：预期共识效应；资产定价；Agent；强化学习

ABSTRACT

With the rapid development of artificial intelligence, investors can process information and make trading decisions more precisely. Whether investors' expectation consensus on specific assets affects asset prices is critical to understanding the operation and stability of financial markets. This paper constructs multi-agent investors with 88 factors as input, adopts the MLP model as the agents' decision-making framework, and explores the pricing effect of agents' expectation consensus through reinforcement learning training. Empirical results show that higher investor expectation consensus corresponds to higher future stock returns, a conclusion that remains robust after multiple checks. Further analysis finds that margin trading and short-selling constraints are the core formation mechanism of this pricing effect, which weakens significantly when such constraints are relaxed. We also document significant heterogeneity: the effect is far more pronounced for small-cap firms, non-state-owned enterprises, and firms in bull market cycles. Finally, we propose corresponding policy recommendations and research prospects based on the findings.

Keywords: Expectation consensus effect; Asset pricing; Agent; Reinforcement learning

目 录

摘 要	I
ABSTRACT	II
1 引言	1
2 文献综述	4
2.1 预期共识度量	4
2.2 预期共识定价效应	5
2.3 基于 Agent 的实验金融研究	6
3 研究设计	8
3.1 Agent 投资者设计	8
3.1.1 数据输入	8
3.1.2 神经网络	10
3.1.3 奖励函数	12
3.1.4 强化学习	13
3.1.5 滚动窗口	15
3.1.6 参数设置	15
3.2 指标设计	16
3.3 数据	17
3.4 系统设计	17
4 实证分析	18
4.1 描述性统计	18
4.2 投资者预期共识定价效应	19

4.2.1	投资组合分析	19
4.2.2	Fama-MacBeth 回归	21
4.3	稳健性检验	22
5	进一步研究	24
5.1	预期共识定价效应的机制分析	24
5.1.1	放松融资融券约束	24
5.1.2	实验结果	25
5.2	异质性分析	26
5.2.1	基于企业市值的异质性分析	27
5.2.2	股权性质异质性分析	28
5.2.3	市场周期异质性分析	29
6	结论与建议	31
	参考文献	32
	致谢	38
	附录 A 因子说明	39
	附录 B 系统设计	46
B.1	系统架构	46
B.1.1	总体架构设计	46
B.1.2	中央控制节点	47
B.1.3	系统组件	47
B.1.4	系统工作流程	48
B.2	数据流水线	49
B.2.1	消息流	49

B.3	训练节点	51
B.3.1	容器化部署环境	51
B.3.2	训练进程	52

1 引言

金融市场是一个具有动态演化特征的复杂协调系统，金融产品价格在很大程度上受到投资者预期的影响。而大量投资者形成的共同预期对资产定价的系统性影响，即“预期共识效应”，是理解市场定价逻辑的重要命题^[1]。长期以来，中国股票市场以散户投资者为主导，贡献了超 80% 的市场交易量^[2]。与机构投资者相比，散户的信息获取与处理能力有限，难以精准解读复杂的公司基本面与市场信号，其决策更易受情绪、短期市场趋势等因素影响^[3]，最终表现为对个股的预期方向呈现显著的集体性乐观或悲观的“共识”^[4]。这种散户主导的“预期共识”现象，是否会成为 A 股资产定价的驱动因素，这一问题尚未得到充分的系统性解答，而其答案直接关联到金融预期政策的实施精度：无论是学术研究^[5]，还是党的会议部署，均强调了引导市场理性预期、维护资本市场稳定的重要性。因此，系统探究 A 股市场中投资者预期共识的定价效应，明确其作用机制、定价效力与适用边界，对于精准实施预期管理、促进资本市场平稳运行，具有重要的理论价值与现实意义。

近年来，机器学习方法在经济、金融、管理等领域受到的重视程度日益提高^[6]。在资产定价领域，因子分析法^{[7][8]}自诞生以来，被广泛应用于资产定价研究。而机器学习方式，以其数据驱动的特性和强大的非线性拟合能力，逐渐成为资产定价研究的热点。Gu, Kelly, Xiu 等学者^[9]通过对比包括随机森林、梯度提升树、感知机在内的 14 种机器学习方法，发现机器学习在挖掘高维公司特征的非线性关系方面具有显著优势，解释力远强于传统因子模型。在国内，李斌等学者^[10]基于 A 股因子，对比了神经网络、支持向量机等模型在 A 股收益预测中的表现，发现机器学习能够有效捕捉 A 股“壳价值”“政策敏感性特征”等特殊定价因素。马甜等学者^[11]将生成式对抗网络引入 A 股因子构建，缓解了因子的稀疏性问题，构建的深度学习复合因子 A 股市场的表现优于传统因子。因子是对公司信息的提取和抽象，而机器学习通过对于因子的非线性拟合，可以模拟投资者对于公司信息的非线性处理过程，从而更准确地预测资产价格。

人工智能技术的发展为金融研究提供了新的视角和工具。Minsky 在 1961 年首次提出了“Agent”的概念^[12]，将 Agent 定义为能够通过协商协作解决问题的

智能个体”，强调其社会交互性、自主性两大核心特性。相比于传统机器学习用于预测、分类等任务，Agent 可以直接模拟投资者“端到端”的决策过程，即收集信息、解读信息、决策、执行、反馈的完整过程^[13]。自 2015 年来，Agent-Based 金融研究数量迅速增加，覆盖了股票价格预测、投资组合管理、风险管理等多个领域^[14]。使用 AI-Agent 模拟投资者决策过程，可以更准确地模拟投资者的决策过程，对于投资者预期协同度的研究具有重要的理论价值与现实意义。

强化学习（Reinforcement Learning, RL）是人工智能领域在序列决策任务中的重要研究方向。在强化学习框架中，Agent 通过与环境交互，学习最优策略，以最大化长期累积奖励，与投资者在金融市场中的决策-学习-反馈-再决策的过程具有一致性。因此，强化学习被广泛应用于金融市场的研究中。在投资组合管理（Portfolio Management, PM）领域，RL 可以灵活设计奖励，纳入交易成本、风险约束、长期收益等目标，解决跨期资产配置问题^[15]；在多 Agent 协同决策（Multi-Agent Reinforcement Learning, MARL）领域，RL 可以模拟多个 Agent 之间的交互，学习最优策略，提供更丰富的资产配置策略^[16]。使用 RL 模拟投资者决策过程，与现实的交易情景更加贴近，将 Agent 投资者置于更真实的场景。

基于已有的研究基础，本文采用 Agent-Based 的实验金融方法，模拟投资者在金融市场中的信息获取、解读、决策、反馈和学习的完整过程。具体而言，本文使用 88 个公司特征作为输入，利用多层感知机（MLP）和近端优化算法（PPO）构建 Agent 投资者，通过滚动窗口的方式，训练 Agent 投资者，同时收集 Agent 的决策数据，通过计算平均决策值（Mean Action, MA），来刻画投资者的预期共识效应。本文从以下几个方面展开研究：首先，本文分析 Agent 投资者的预期共识的定价效应；其次，从融资和融券约束的角度，探讨预期共识定价效应的形成机制；最后，从企业市值、股权异质性和市场周期的角度，分析预期共识定价效应的异质性。

本文得到如下几方面结论：第一，在中国 A 股市场中，投资者预期共识的定价效应显著，预期共识水平越高，股票未来收益越高，这一结论在一系列稳健性检验后依然成立；第二，融资和融券约束是预期共识定价效应的重要形成机制，在放松融资和融券约束后，预期共识定价效应显著减弱；第三，企业市值、股权异质性和市场周期是预期共识定价效应的异质性来源，小市值、民营企业、牛市

周期中，预期共识定价效应更为显著。

本文的创新之处体现在以下几个方面：第一，区别于传统的预期共识度量，本文使用实验金融的方法，刻画个体投资者的预期水平。其次，本文系统的研究了预期共识效应的定价效应，提供了新的因子集成学习方法。再次，本文通过实验金融的方式，放松融资和融券约束，研究了预期共识定价效应的形成机制。最后，本文探讨了预期共识定价效应在不同市值、股权异质性和市场周期中的异质性。

2 文献综述

2.1 预期共识度量

本文所指的预期共识，是投资者对个股未来收益的“整体预期方向与平均水平”。因此，如何度量单个投资者的预期水平，是研究预期共识效应的关键。然而，在传统的金融实证研究中，度量单个投资者的预期较为困难，方法主要集中于调研的宏观预期指标、代理指标、分析师预期分歧和文本分析^[17]，间接衡量投资者的预期水平。然而，这些方法均存在局限性。

宏观预期指标通过调研消费者信心或经济预期反映市场整体情绪，典型代表如密歇根大学消费者信心指数、MM 经济预期指数。Lemmon 等学者曾使用这类指数作为投资者乐观程度的代理变量^[18]，分析其对小市值股票溢价的影响。但此类指标聚焦宏观经济层面，反映的是全市场整体情绪趋势，无法精准捕捉个股层面的预期共识；

市场代理指标通过金融市场交易数据间接映射投资者预期共识。朱宏泉等学者^[19]使用未预期到的换手率作为代理变量，剔除习惯性交易、流动性需求等无关因素后，间接反映投资者对个股的预期共识变动；孟庆斌等学者^[20]则以卖空量作为悲观预期共识的代理指标，认为卖空行为的聚合体现了市场对个股的集体看空倾向。但这类指标存在明显局限。未预期换手率仅能反映共识的“变动趋势”，无法直接量化共识的具体方向与强度。卖空量仅能覆盖悲观共识，难以全面捕捉乐观共识，存在维度片面性。并且，上述方法也均无法直接刻画散户群体的真实预期倾向。

分析师预期聚合通过汇总专业分析师的预测结果近似反映预期共识。Diether 等学者曾基于分析师盈余预测的均值构建预期水平指标^[21]，Anderson 等学者则通过分析师长期盈余增长预测的平均水平衡量共识强度^[22]。但分析师群体的局限性显著：一是样本覆盖不足，难以覆盖全时期、全证券的预期共识，尤其对中小盘个股的覆盖缺口较大；二是代表性偏差，分析师多服务于机构投资者，其预期难以替代散户主导市场的集体共识；三是预测失真风险，分析师预测易受自身利益冲突、行业压力等因素影响^[23]，导致共识度量的真实性受损。

文本情绪分析法通过挖掘非结构化文本数据中的情绪倾向，聚合形成预期

共识。部慧等学者利用股评文本构建投资者情绪指数^[24]，万海远等学者通过企业调研文本与政策文本分析企业预期变动^[25]，均试图通过文本聚合捕捉市场共识。但此类方法面临多重挑战，如数据存在大量噪声，刻意披露行为，信息密度低等问题。

随着机器学习和人工智能技术的发展，Agent 的使用为刻画投资者预期提供了全新的视角。Hornik 等学者在其经典研究中证明了多层感知机 (MLP) 可以逼近任意连续函数^[26]。因此，基于神经网络的 Agent 可以模拟投资者在真实市场中对于信息的处理和决策过程，从而较好地刻画单个投资者预期。投资者的信念受其获取的信息^[27]，和对于信息解读^[28]^[29]的过程影响。对于 Agent，其输入和解读的方式都可以通过调整神经网络参数的方式进行模拟，从而更贴合真实投资者的行为。唐国豪等学者^[17]通过多个神经网络，构建了投资者预期协同度量模型，使用不同初始化参数的多层感知机模拟单个投资者的预期。因此，使用 Agent 模拟单个投资者，在理论和实践上均有可行性，为解决预期共识度量问题提供了新的思路。

2.2 预期共识定价效应

Miller 在 1977 年提出的经典假说：在存在卖空约束的市场中，悲观投资者无法通过卖空交易充分表达其负面预期，资产价格将主要由乐观投资者的信念决定；投资者预期分歧越大，预期共识越低，股价被乐观预期高估的程度就越严重，对应的股票未来收益也越低^[30]。这一假设成为投资者预期在资本市场定价中的重要基石。在实证研究中，Diether 等学者使用分析师预期分歧^[21]，Johnson 使用期权定价理论^[31]，Yu 从资产组合视角出发，均验证了预期共识越低，股票未来收益越低的结论。而 Greenwood 和 Shleifer 使用美国投资者的预期调研数据，直接度量了投资者的预期共识，发现预期共识度越高，股票未来收益越高^[1]。国内，唐国豪等学者使用大量神经网络模型，模拟异质性个体投资者的预期，验证了预期共识越低，股票未来收益越低的结论^[17]。

关于预期共识定价的机制，一种主要的解释是做空约束引发的错误定价。根据 Miller 的假说^[30]，在具有卖空约束的市场中，悲观的投资者无法通过做空实现自己的收益，无法具体表达自己的预期，因此，股价被乐观投资者的信念决定。

这使得股票价格系统性偏离基本面而出现高估，而当市场预期逐步向理性回归时，股价会向内在价值修正，最终导致高分歧（低共识）股票的未来收益显著降低。Boehme 等^[32]进一步完善了这一逻辑，指出卖空约束与投资者意见分歧的共同作用是股价高估的必要条件，单一因素的存在并不会引发系统性的错误定价，只有二者叠加时，悲观投资者的观点缺失才会让乐观预期主导定价。Park^[33]则从投机性定价视角补充了该机制，认为卖空约束下的高预期分歧会催生投资者的投机动机，即投资者因预期未来能以更高价格转售股票而推高当前股价，这种投机性的定价行为进一步放大了错误定价的程度，使得预期共识水平与股票未来收益呈现出显著的正相关关系。而当市场存在有效的套利机制、卖空约束被放松时，悲观投资者能够通过做空行为表达自身观点，市场定价能更充分地反映多方面的预期信息，预期分歧引发的错误定价会被有效修正，预期共识对股票收益的定价效应也会相应减弱。

2.3 基于 Agent 的实验金融研究

随着 AI 技术的发展，Agent 已经被广泛应用于实验金融领域^[14]。

Agent 因其输入、计算、反馈的灵活性，已经被广泛用于实验金融，模拟个体投资者的决策过程。Henning 等学者^[34]使用 Agent 模拟大量投资者在市场上的交易行为，发现 Agent 的决策过程相比于人类有着“教科书式理性”，不会出现市场泡沫等非理性行为。AI-Hedge Fund 项目拓展了多智能体协作的投资决策场景，通过构建包含价值投资、成长投资、逆向投资等多元风格的专家智能体与功能分析模块，实现了从信息整合、风险评估到组合决策的全流程投资模拟，为探究专业化投资群体的预期聚合机制提供了可复用的技术框架^[35]。TwinMarket 系统在 A 股市场环境中，使用多 Agent 系统模拟散户的预期互动、情绪传染等现象，探究行为金融与价格形成的关系^[36]。

强化学习作为一种机器学习范式，通过智能体与环境的交互学习最优策略，已在金融交易领域展现出巨大潜力。与传统监督学习相比，RL 能够灵活地考虑交易成本、风险控制等因素，并直接生成动态的资产权重分配策略^{[37][38]}。

Liu 等人^[39]开发的 FinRL 框架，成为金融强化学习研究的重要工具。该框架定义了滚动窗口训练方式，输入为一个维度为 $(n, m, l + 1)$ 的三维张量，其中 n 为

证券数量，表示证券组合中的证券数量； m 为时间窗口长度，表示 Agent 可以回顾过去 m 个月的数据； l 为因子数量，可以由用户自定义因子计算模式，并附带一个现金项。随后，将该三维张量进行展平，使用 MLP 模型作为 Agent 决策模型，输出为 $n + 1$ 维向量，对应 n 只证券的权重及一个现金项。该框架支持多种强化学习算法，包括 PPO, DNQ 等，并提供了丰富的奖励函数和评估指标，包括收益率，夏普比率等。

3 研究设计

3.1 Agent 投资者设计

对于一个 Agent 投资者，其决策和学习的过程可以分为以下几个步骤：

算法 1: Agent 投资者决策过程

Input: 特征数据

Result: 更新后的神经网络

- 1 特征数据 $\xrightarrow{\text{神经网络}}$ 投资决策 @;
 - 2 投资决策、收益数据 $\rightarrow$ 组合收益;
 - 3 组合收益序列 $\rightarrow$ 组合表现指标（如波动率、夏普比率、最大回撤等）;
 - 4 组合表现指标 $\rightarrow$ 奖励;
 - 5 奖励 $\rightarrow$ 更新后的神经网络;
 - 6 重复上述步骤，直到达到预设的训练次数或达到预设的训练时间。
-

@收集结果用于计算 MA 因子

根据上述步骤，可以设计一个 Agent 投资者的决策和学习过程。

3.1.1 数据输入

使用因子数据作为 Agent 投资者的输入，用于模拟投资者对于因子的解读和决策。因子数据是以年月-证券为主键的月度面板数据。记原始的因子数据为 $raw_factors_{a,s,t,i}$ ，表示第 a 个 Agent 在 t 月份对于证券 s 的因子 i 的原始值。

由于不同特征的量纲、数量级、分布等方面存在明显差异，因此需要对特征进行标准化处理，使得所有特征的均值为 0，标准差为 1。具体来说，记 N 为参与该月标准化的证券数量（如股票池大小）。对于每一个因子 $factor_{a,s,t,i}$ ，求相同月份所有证券的因子值的均值和标准差：

$$raw_mu_{t,i} = \frac{1}{N} \sum_{s=1}^N raw_factors_{a,s,t,i}$$

$$raw_sigma_{t,i} = \sqrt{\frac{1}{N} \sum_{s=1}^N (raw_factors_{a,s,t,i} - raw_mu_{t,i})^2}$$

然后对每一个因子进行标准化处理，得到标准化后的因子值：

$$factor_{a,s,t,i} = \frac{raw_factors_{a,s,t,i} - raw_μ_{t,i}}{raw_σ_{t,i}}$$

参考 FinRL^[39] 的设计，设定一个因子向量为：

$$\vec{factors}_{a,s,t} = (factor_{a,s,t,1}, factor_{a,s,t,2}, \dots, factor_{a,s,t,i}, \dots)^T$$

考虑到不同的 Agent 投资者的数据获取能力不同，对数据的关注程度也不同，可以使用“随机选择”的方法定义不同的投资者^[40]，类似于机器学习中的特征选择方法^[41]。设定 Agent_{*a*} 只能随机获取 88 个因子中的 *l* 个因子，用于分析决策。筛选后的因子向量为：

$$selected_factors_{a,s,t} = (factor_{a,s,t,random_1}, factor_{a,s,t,random_2}, \dots, factor_{a,s,t,random_i}, \dots)^T$$

其中 $random_i$ 为随机选择的因子索引，不同的 Agent 投资者选择的因子索引不同。

设定 Agent 拥有一定的数据回顾能力，可以回顾过去 *m* 个月的因子向量。在月份 *t*，Agent 可以回顾过去 *m* 个月的因子向量，形成一个 (*m*, *l*) 的矩阵，记作：

$$factors_matrix_{a,s,t} = (\vec{factors}_{a,s,t}, \vec{factors}_{a,s,t-1}, \dots, \vec{factors}_{a,s,t-m+1})$$

Agent 需要选择 *n* 只证券，构建一个投资组合，记作：

$$portfolio = (s_1, s_2, \dots, s_n)$$

将多个证券的因子矩阵拼接，可以得到一个三维张量，记作：

$$factors_tensor_{a,portfolio,t} = \begin{pmatrix} factors_matrix_{a,s_1,t} \\ factors_matrix_{a,s_2,t} \\ \vdots \\ factors_matrix_{a,s_n,t} \end{pmatrix}$$

其维度为 (*n*, *m*, *l*)。

最后，Agent 可以回顾自己之前投资组合的收益情况，对于投资组合 $portfolio$ ，获取其 $t, t-1, t-2, \dots, t-m+1$ 月的收益，组成收益序列，记作：

$$returns_{a,portfolio,t} = (return_{a,portfolio,t-m+1}, return_{a,portfolio,t-m+2}, \dots, return_{a,portfolio,t})$$

其中， $return_{a,portfolio,t}$ 为使用 $t-1$ 月的决策构建投资组合 $portfolio$ 在 *t* 月份的收益。其计算方式为各个证券在 $t-1$ 月的决策水平其在 *t* 月份的收益水平

的加权平均值。记 $w_{a,portfolio,t,s}$ 为第 a 个 Agent 在 t 月份对于证券 s 的决策权重， $return_{s,t}$ 为证券 s 在 t 月份的收益，则：

$$return_{a,portfolio,t} = \sum_{s=1}^{n+1} w_{a,portfolio,t-1,s} \cdot return_{s,t}$$

其中， $w_{a,portfolio,t,n+1}$ 为现金权重，表示分配给无风险资产（现金）的比例，对应 $return_{n+1,t}$ 为无风险收益率。

该收益序列与具体证券无关，为组合整体收益。为与按证券组织的输入一致，将该收益序列复制 n 份，得到形状为 (n, m) 的矩阵（每行均为同一 m 维收益序列），记作：

$$\mathbf{returns_matrix}_{a,portfolio,t} = \begin{pmatrix} return_{a,portfolio,t-m+1} & return_{a,portfolio,t-m+2} & \dots & return_{a,portfolio,t} \\ return_{a,portfolio,t-m+1} & return_{a,portfolio,t-m+2} & \dots & return_{a,portfolio,t} \\ \vdots & \vdots & \vdots & \vdots \\ return_{a,portfolio,t-m+1} & return_{a,portfolio,t-m+2} & \dots & return_{a,portfolio,t} \end{pmatrix}$$

再将该矩阵在特征维上扩展为形状为 $(n, m, 1)$ 的三维张量，并与原有 (n, m, l) 张量在特征维上拼接，得到最终输入张量，其维度为 $(n, m, l+1)$ ，记作：

$$\mathbf{X}_{a,portfolio,t} = \begin{pmatrix} \mathbf{factors_matrix}_{a,s_1,t} \\ \mathbf{factors_matrix}_{a,s_2,t} \\ \vdots \\ \mathbf{factors_matrix}_{a,s_n,t} \\ \mathbf{returns_matrix}_{a,portfolio,t} \end{pmatrix}$$

3.1.2 神经网络

与预测模型不同，Agent 的神经网络采用端到端设计，无需预测组合未来的收益，而是直接进行决策，决定将多少比例的资金分配给每只证券（现金）。

（1）数据输入层：参考 FinRL^[39]，采用多层感知机（MLP）作为 Agent 由观测到投资权重的映射模型。输入为前述的观测张量 $\mathbf{X}_{a,portfolio,t}$ ，形状为 $(n, m, l+1)$ 。

（2）展平与线性层：将输入张量展平为一维向量，记作：

$$\mathbf{x} = \text{Flatten}(\mathbf{X}_{a,portfolio,t}) \quad \mathbf{x} \in \mathbb{R}^{nm(l+1)}$$

经过 Dropout 层后，得到：

$$\mathbf{x}' = \text{Dropout}(\mathbf{x}) \quad \mathbf{x}' \in \mathbb{R}^{nm(l+1)}$$

然后通过一层全连接层映射为 $n+1$ 维向量，记作：

$$\mathbf{z} = \mathbf{W} \mathbf{x}' + \mathbf{b} \quad \mathbf{W} \in \mathbb{R}^{(n+1) \times nm(l+1)}, \mathbf{b} \in \mathbb{R}^{n+1},$$

得到 $\mathbf{z} \in \mathbb{R}^{n+1}$ ，对应 n 只证券的权重及一个现金（无风险资产）维度。

(3) **激活函数**：使用 Tanh 函数作为激活函数，将输出映射到 $(-1, 1)$ 之间。

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

经过 Tanh 函数激活后，得到模型输出，记作：

$$\mathbf{o}_{a, portfolio, t} = \tanh(\mathbf{z}) \quad \mathbf{o}_{a, portfolio, t} \in \mathbb{R}^{n+1}$$

使用 Tanh 作为激活函数，可以保留负权重，用于后续研究中放松对于杠杆和做空的限制。

(4) **输出归一化**：按照决策的语义，Agent 的决策（行动）可以表示为一个和为 1 的向量，记作：

$$\vec{action}_{a, portfolio, t} = (w_1, w_2, \dots, w_{n+1}) \in \mathbb{R}^{n+1}$$

其中， w_i 表示分配给证券（现金） i 的比例。设定最后一个权重 w_{n+1} 为现金权重，表示分配给无风险资产（现金）的比例。

在基线回归中，设定不允许使用杠杆或者做空。因此，将 $\mathbf{o}_{a, portfolio, t}$ 转换为决策向量 $\vec{action}_{a, portfolio, t}$ ，需要满足以下约束：

1) 权重之和为 1，即 $\sum_{i=1}^{n+1} w_i = 1$ ，表示需要将全部资金用完，无用的资金需要分配给无风险资产（现金）；

2) 非负，即 $w_i \geq 0$ ，表示不允许做空证券，或者使用杠杆（即现金权重为负，表示借入资金购买证券）；

将 $\mathbf{o}_{a, portfolio, t}$ 记作：

$$\mathbf{o}_{a, portfolio, t} = (o_1, o_2, \dots, o_{n+1})$$

为了满足非负性约束，将 $\mathbf{o}_{a, portfolio, t}$ 中的负权重部分截断为 0，得到：

$$o_i^+ = \max(o_i, 0)$$

$$\mathbf{o}_{a, portfolio, t}^+ = (o_1^+, o_2^+, \dots, o_{n+1}^+)$$

然后进行简单归一化，得到归一化后的决策向量，记作：

$$\vec{action}_{a,portfolio,t} = \left(\frac{o_1^+}{\sum_{i=1}^{n+1} o_i^+}, \dots, \frac{o_{n+1}^+}{\sum_{i=1}^{n+1} o_i^+} \right)$$

3.1.3 奖励函数

在强化学习中，奖励函数是 Agent 用于评估其决策好坏，改进决策方向，实现模型优化的关键。参考 Moody 等^[42]和 jiang 等^[43]的研究，使用二次效用函数^[44]作为奖励函数。

$$u = \mu - \frac{A}{2}\sigma^2$$

具体来说,对于一个投资组合 $portfolio$,其在 t 月份的收益率为 $return_{a,portfolio,t}$ 。由于可能涉及采样算法，计算奖励前，需要再对 $\vec{action}_{a,portfolio,t}$ 进行归一化。后续计算方式和前述相同。

Agent 在 t 时间点上决策，获取 $\vec{action}_{a,portfolio,t}$ ，计算持有该组合到下一个时间点期间的收益 $return_{a,portfolio,t+1}$ ，作为期望收益 μ 。

再获取其前 m 个月的收益序列：

$$\vec{returns}_{portfolio,t} = (return_{portfolio,t}, return_{portfolio,t-1}, \dots, return_{portfolio,t-m+1})$$

计算历史收益的样本均值：

$$\bar{r}_{portfolio,t} = \frac{1}{m} \sum_{i=0}^{m-1} return_{portfolio,t-i}$$

然后计算历史收益的方差：

$$\sigma^2 = \frac{1}{m} \sum_{i=0}^{m-1} (return_{portfolio,t-i} - \bar{r}_{portfolio,t})^2$$

参数 A 是风险厌恶系数。 A 越大，表明 Agent 越厌恶风险，越倾向于选择低风险的组合。根据尹海员等^[45]、张玥^[46]、jiang^[47]等学者的研究，在 A 股市场中，投资者的风险系数的取值范围在 $[2, 8]$ 之间，具有厚尾、右偏的分布特征。因此，使用对数正态分布采样 Agent 的风险厌恶系数。

$$\ln(A) \sim N(\mu_A, \sigma_A^2)$$

该分布具有恒正、右偏、厚尾的特征，符合投资者风险厌恶系数的分布特征。

3.1.4 强化学习

3.1.4.1 游戏设定

在本研究中，将投资组合决策建模为单步强化学习环境，每一次决策构成一局完整的游戏。在该设定下，Agent 在观测到因子数据后 obs 后，根据当前策略做出决策 $action$ ，并返回奖励 $reward$ 。 $reward$ 由二次效用函数计算得到，记作 $reward = u(obs, action)$ 记每局对应一个转移 $(obs, action, reward)$ 。

强化学习的目标为，得到一个策略 π ，使得在观察到因子数据 obs 后，根据策略 π 做出的决策 $action$ ，能够最大化奖励 $reward$ 。

记策略 $\pi = \pi(action|obs)$ ，表示在 obs 观测下，做出决策 $action$ 的概率。则学习目标为：

$$J(\pi) = \mathbb{E}_{obs, action \sim \pi}[reward(obs, action)]$$

定义神经网络的参数为 θ ，则策略 π 可以表示为：

$$\pi_{\theta}(action|obs)$$

优化目标为：

$$J(\theta) = \mathbb{E}_{obs, action \sim \pi}[reward(obs, action)]$$

3.1.4.2 PPO 算法

使用近端策略优化（Proximal Policy Optimization, PPO）算法作为强化学习算法。PPO 策略由 Schulman 等^[48]提出，是一种基于策略梯度算法的强化学习算法。通过计算新的策略与当前策略的优势更新策略，并且通过限制概率比和裁剪的方式，避免策略更新幅度过大。该算法具有较好的收敛性和稳定性，适用于连续动作空间的问题。

使用 Stable-Baselines3(SB3)^[49]框架实现 PPO 算法。

(1) Actor-Critic 网络： PPO 使用 Actor-Critic 网络优化策略。Actor 网络用于生成策略，使用前述的神经网络 f 作为 Actor 网络。Actor 网络将 $f_{\theta}(obs)$ 映射为均值为 $f_{\theta}(obs)$ ，方差为 σ^2 的正态分布，在以这个分布作为策略 $\pi_{\theta}(action|obs)$ ，探索动作空间，记为：

$$\pi_{\theta}(action|obs) \sim \mathcal{N}(f_{\theta}(obs), \sigma^2)$$

价值函数 $V_\phi(obs)$ 用于评估当前策略的优劣势，其中， ϕ 为 Critic 网络的参数。用于拟合状态价值函数：

$$V^\pi(obs) = \mathbb{E}_{action \sim \pi(\cdot|obs)}[reward(obs, action)]$$

Critic 学习对上述期望的近似，即 $V_\phi(obs) \approx V^\pi(obs)$ ，作为基线，评估实际奖励 $reward$ 与期望奖励 $V^\pi(obs)$ 的差距：

$$\hat{A}(obs, action) = reward(obs, action) - V_\phi(obs)$$

通过不断训练，Critic 网络改进对于 $reward$ 的近似，是的后续计算更加准确。

(2) 优化目标：PPO 的优化目标基于三项损失的和，分别是策略损失、价值损失和熵正则项。

优化策略损失，使得策略朝着奖励增大的方向更新。具体来说，给定优势 $\hat{A}$ ，如果 $\hat{A} > 0$ ，则应该提高 $\pi_\theta(action|obs)$ ，如果 $\hat{A} < 0$ ，则应该降低 $\pi_\theta(action|obs)$ 。定义概率比：

$$ratio(\theta) = \frac{\pi_\theta(action|obs)}{\pi_{\theta_{old}}(action|obs)}$$

表示新策略相对旧策略在该 $(obs, action)$ 上的概率密度之比。 $ratio(\theta)$ 越大，新策略越倾向做该动作。使用概率比和 $\hat{A}$ 的乘积可以衡量策略损失：

$$L^{PG}(\theta) = \mathbb{E}_{(obs, action, reward) \sim \mathcal{D}}[ratio(\theta) \cdot \hat{A}(obs, action)]$$

其中 $\mathcal{D}$ 为多局单步游戏收集的 $(obs, action, reward)$ 组成的集合。设定损失函数为 $-L^{PG}(\theta)$ 。最小化损失函数，即最大化 $L^{PG}(\theta)$ ，让 θ 朝着奖励增大的方向更新。

为了防止更新幅度过大，定义经过裁剪策略损失：

$$L^{CLIP}(\theta) = \mathbb{E}_{(obs, action, reward) \sim \mathcal{D}}[\min(ratio(\theta) \cdot \hat{A}, 1 - \epsilon, 1 + \epsilon)]$$

核心是使用 `clip` 函数裁剪 $ratio$ 。 ϵ 为裁剪半径，裁剪函数 $clip(r(\theta), 1 - \epsilon, 1 + \epsilon)$ 将概率比截断在 $[1 - \epsilon, 1 + \epsilon]$ ，以限制更新幅度。同理，使用 $-L^{CLIP}(\theta)$ 作为损失函数。

除了策略项更新，还需要更新 Critic 网络。定义价值损失：

$$L^{VF}(\phi) = \mathbb{E}_{(obs, action, reward) \sim \mathcal{D}}[(V_\phi(obs) - reward)^2].$$

价值损失越小，Critic 网络拟合的奖励越接近真实奖励，评价效果越好。

最后，提供一个熵正则项，用于提高策略的探索性：

$$L^H(\theta) = \mathbb{E}_{(obs, action) \sim \mathcal{D}}[H(\pi(\theta(\cdot|obs)))]$$

熵越大，动作分布越均匀，探索越多。定义熵正则损失为 $-L^H(\theta)$ ，熵正则损失越小，探索性越高。

将三项损失线性相加，得到最终损失：

$$\mathcal{L}(\theta, \phi) = -L^{CLIP}(\theta) + c_1 \cdot \mathcal{L}^{VF}(\phi) - c_2 \cdot L^H(\theta)$$

优化最终损失 $\mathcal{L}(\theta, \phi)$ ，可以使得策略朝着奖励增大的方向更新，同时保持策略的探索性。

最后，为了避免过拟合，对模型进行正则化处理：`clip_grad_norm` 对梯度范数进行裁剪，防止梯度爆炸、保证更新稳定；`weight_decay` 对权重施加 L^2 惩罚，抑制权重过大、减轻过拟合。

3.1.5 滚动窗口

参考唐国豪^[17]，FinRL^[39]等做法，使用滚动窗口的方式训练 Agent，同时收集数据，用于后续因子构建。

由于计算奖励需要单个证券组合的历史收益序列，需要确保证券组合在窗口中保持不变。因此，进行提前采样，对于证券池 $\mathcal{S}$ ，一共有 S 只证券，若一个证券组合由 n 只证券组成，则最多可构建 $\binom{S}{n}$ 个不同的证券组合。选取其中 N 个证券组合 $\mathcal{P} = \{\vec{portfolio}_1, \vec{portfolio}_2, \dots, \vec{portfolio}_N\}$ 。

对于一个时间窗口 t ，遍历所有证券组合 $\vec{portfolio} \in \mathcal{P}$ ，每次输入观测 $\mathbf{X}_{a, \vec{portfolio}, t}$ ，得到决策 $action_{a, \vec{portfolio}, t}$ ，计算奖励 $reward(obs, action)$ ，更新网络参数。遍历完成后，进入下一个时间窗口 $t+1$ ，然后打乱 $\mathcal{P}$ ，重复上述过程。

3.1.6 参数设置

本文的核心参数设置如下。

MLP 网络相关参数见表3.1。其中，证券组合的证券数 n 取 1，即每次只决策一个证券，与后文为单个证券计算预期共识的设定保持一致。

表 3.1 MLP 与正则化参数

参数	定义	取值
n	资产组合包含的证券数	1
m	因子回看期数	12
l	读取因子数量（掩码长度）	60
N	每个窗口构建的资产组合数	5000（足够覆盖全部证券）
agents	投资者数量	30
dropout	神经元丢弃比例	0.25
activation	激活函数	Tanh

PPO 算法的主要超参数见表3.2。

表 3.2 PPO 算法超参数

参数	定义	取值
lr	学习率	5×10^{-4}
ϵ	裁剪半径	0.2
vf_coef	价值损失权重（ c_1 ）	0.5
ent_coef	熵正则权重（ c_2 ）	0.0
clip_grad_norm	梯度裁剪范数	0.5
weight_decay	权重衰减	0.1

奖励函数的风险厌恶系数参数 A 见表3.3。该设定使 A 取值集中在 $[2, 8]$ 附近，具有右偏、厚尾特征，用于刻画投资者风险厌恶的异质性；每个 Agent 独立从该分布采样一个 A 并用于计算效用与奖励。

表 3.3 风险厌恶系数 A 的分布参数

参数	定义	取值
μ_A	A 的对数均值	1
σ_A^2	A 的对数方差	0.16

3.2 指标设计

为了刻画 Agent 投资者的预期共识效应，参考唐国豪等^[17]、Bali 等^[40]、Hong 等^[50]、Banerjee 等^[51]的做法，构建 $MA_{s,t}$ 指标，即 Agent 的平均决策值 (Mean Action, MA)，用于刻画 Agent 投资者的预期共识效应。

具体来说，第 a 个 Agent 对于证券 s 的投资决策为 $action_{a,s,t}$ ，记 $MA_{s,t}$ 为 t 月份证券 s 的平均投资决策：

$$MA_{s,t} = \frac{1}{N} \sum_{a=1}^N action_{a,s,t}$$

平均决策值可以衡量 Agent 对于证券 s 的预期共识程度。如果平均决策值较大，则表示 Agent 对于证券 s 的决策值高，整体看多证券 s ；如果平均决策值较小，则表示 Agent 对于证券 s 的决策值低，整体看空证券 s 。

3.3 数据

样本选取方面，本研究以 2004 年 1 月至 2024 年 12 月为研究区间，以中国 A 股市场（含上证、深证、创业板和科创板）为研究对象，数据均为月度频率。

在因子选取方面，本文使用了李斌等学者^[10]针对中国 A 股市场系统性梳理与构建的 96 个定价因子库，该因子库全面覆盖了交易摩擦、财务流动性、成长性、动量、盈利、价值等大类的公司基本面与市场交易特征。本文最终使用其中的 88 个因子，作为 Agent 的观测因子。具体的因子列表见附录 A。

本文的证券收益、Fama-French 五因子，股权性质、市值数据、账面市值比、毛利率、投资比率等数据均来自 CSMAR 数据库。

在收集数据后，进行数据处理。具体处理过程为：第一，剔除 ST,*ST 证券，这些证券往往处于财务困境，不宜进行分析。第二，为了保证证券组合在窗口中保持不变，剔除在 2024 年 12 月 31 日之前退市的证券。第三，由于金融类企业的财务核算方式与普通企业不同，因此剔除金融类证券。第四，缺失值处理。（1）对于缺失值，参考李斌等学者^[10]的做法，对于收益缺失的观测，通常是由于停牌等原因造成，将其剔除；（2）对于因子数据缺失，为了避免数据泄露，采用前向填充的方式，用前一期的因子值填充缺失值。再填充后，剩余的缺失值用 0 填充。Fama-MacBeth 回归中，缺失值的填充方式一致。（3）由于核算奖励需要历史序列，对于收益大量缺失的证券（缺失率大于 20%），进行剔除。最后，由于不同证券的上市时间不同，对于窗口内未上市的证券，使用 0 填充其因子值和收益，并在训练阶段约定跳过。

3.4 系统设计

由于本研究涉及的训练任务规模庞大，传统的单机训练方式无法满足需求。因此，本研究设计了一个基于“数据流水线”和“分布式训练”的计算集群，解决了数据加载、处理、训练的效率问题。具体的系统设计见附录 B。

4 实证分析

4.1 描述性统计

本文首先对核心变量进行描述性统计，结果如表 4.1 和 4.2 所示。

表 4.1 描述性统计 (1)

变量	观测数	缺失数	均值	标准差
MA	402640	0	0.669	0.114
月收益率	402640	0	0.004	0.135
beta	998924	1076	1.111	5.738
账面市值比	325753	674247	0.651	0.264
对数流通市值	999501	499	15.061	1.320
毛利率	318602	681398	0.265	3.826
投资比率	402584	597416	0.943	0.103

表 4.2 描述性统计 (2)

变量	最小值	25% 分位数	50% 分位数	75% 分位数	最大值
MA	0.000	0.597	0.682	0.753	1.000
月收益率	-0.837	-0.066	-0.003	0.061	4.153
beta	-2376.667	0.728	1.101	1.478	2540.833
对数流通市值	9.939	14.188	14.985	15.818	21.748
账面市值比	-0.222	0.465	0.656	0.836	43.588
毛利率	-2137.804	0.151	0.245	0.371	2.161
投资比率	-0.311	0.935	0.990	1.000	1.233

本文对核心变量 MA，月收益率和 Fama-MacBeth 回归的控制变量进行描述性统计，预期共识度（MA）有效观测数 402640 个，无缺失值；其值范围为 [0.000, 1.000]，符合不允许杠杆和做空的语义；其 25% 分位数和 75% 分位数相对集中，说明 MA 构造可以缓解 Agent 决策方差较大的问题。

被解释变量股票月收益率有效观测数 402640 个，无缺失值；其分布呈现典型尖峰厚尾特征，极值区间为 [-0.837, 4.153]，反映个股收益分化明显。

控制变量方面，市场贝塔（beta）有效观测数 998924 个，均值 1.111，略高于市场平均水平，存在少量极端值；账面市值比有效观测数 325753 个，均值 0.651，分布对称；毛利率有效观测数 318602 个，均值 0.265，盈利水平分化显著；投资

比率有效观测数 402584 个，均值 0.943，整体接近 1；对数流通市值有效观测数 999501 个，均值 15.061，规模分布均匀，覆盖大中小市值个股。

4.2 投资者预期共识定价效应

4.2.1 投资组合分析

投资组合分析法是实证资产定价研究的常用非参数方法，该方法无需对变量间关系施加线性假设，对极端值也具备较强的稳健性。

本文使用该方法检验预期共识因子的定价效应。具体而言，在月度频率下，对每个月所有 A 股证券的 MA 指标进行排序，按照九等分位点将证券划分为 10 组，其中第 1 组为 MA 水平最小的 10% 证券，第 2 组为 MA 水平次小的 10% 证券，以此类推，第 10 组为 MA 水平最大的 10% 证券。随后，对每个分组内的证券按流通市值进行加权，构建月度再平衡的投资组合，并计算各组合的月度收益率序列。在此基础上，构建“对冲组合”：以做多第 10 组、做空第 1 组的方式，计算每期多空收益差，得到对冲组合的收益序列。

各组合的平均收益率如表 4.3 的第 2 列所示。为验证组合收益率是否显著异于 0，本文对收益序列进行 t 检验，并针对收益序列的序列相关性与异方差性，使用 Newey-West 标准误进行修正。结果显示，随着 MA 水平的提升，组合平均收益率呈现严格的单调上升趋势，从第 1 组的 -0.232%（5% 水平显著）逐步提升至第 10 组的 0.148%（1% 水平显著）；对冲组合的月度平均收益率达到 0.380%，且在 1% 的统计水平下显著为正。各组合的夏普比率如表 4.3 的第 3 列所示。伴随 MA 水平的提升，组合夏普比率同样呈现单调上升特征，从第 1 组的 -14.550% 提升至第 10 组的 43.880%，说明 MA 水平越高的证券，承担单位风险所能获取的收益越高，具备更优的收益风险比。

本文进一步使用 CAPM 模型、Fama-French 三因子模型与 Fama-French 五因子模型，计算各组合的风险调整后收益，结果如表 4.3 的第 4-6 列所示。在经过经典风险因子调整后，对冲组合仍具有显著为正的 α 收益：CAPM 模型下 α 为 0.250%（1% 水平显著），Fama-French 三因子模型下 α 为 0.237%（1% 水平显著），Fama-French 五因子模型下 α 为 0.207%（5% 水平显著）。这说明 MA 带来的超额收益，无法由市场、规模、价值等常见风险因素解释。

表 4.3 分组检验与对冲组合收益表现

分组 ID	平均收益率	夏普比率	CAPM Alpha	FF3 Alpha	FF5 Alpha
组合 1	-0.232** [-2.231] (0.026)	-14.550	-0.358*** [-3.541] (0.000)	-0.337*** [-3.432] (0.001)	-0.297*** [-2.998] (0.003)
组合 2	-0.062 [-0.702] (0.483)	-5.234	-0.193** [-2.305] (0.021)	-0.173** [-2.173] (0.030)	-0.154* [-1.930] (0.054)
组合 3	-0.017 [-0.236] (0.814)	-1.748	-0.155** [-2.365] (0.018)	-0.148** [-2.347] (0.019)	-0.122** [-1.994] (0.046)
组合 4	0.039 [0.580] (0.562)	4.524	-0.098* [-1.735] (0.083)	-0.092* [-1.702] (0.089)	-0.068 [-1.292] (0.196)
组合 5	0.048 [0.830] (0.406)	6.376	-0.086* [-1.753] (0.080)	-0.076 [-1.591] (0.112)	-0.061 [-1.266] (0.205)
组合 6	0.096* [1.854] (0.064)	13.760	-0.035 [-0.765] (0.444)	-0.026 [-0.578] (0.563)	-0.011 [-0.241] (0.810)
组合 7	0.100** [2.307] (0.021)	18.070	-0.036 [-1.011] (0.312)	-0.028 [-0.825] (0.410)	-0.010 [-0.315] (0.753)
组合 8	0.124*** [3.235] (0.001)	25.330	-0.010 [-0.315] (0.753)	-0.002 [-0.070] (0.944)	0.007 [0.239] (0.811)
组合 9	0.138*** [4.323] (0.000)	32.200	0.006 [0.219] (0.826)	0.014 [0.562] (0.574)	0.025 [1.006] (0.315)
组合 10	0.148*** [5.744] (0.000)	43.880	0.018 [0.778] (0.437)	0.024 [1.099] (0.272)	0.035 [1.540] (0.124)
对冲组合	0.380*** [4.045] (0.000)	26.840	0.250*** [2.686] (0.007)	0.237*** [2.608] (0.009)	0.207** [2.247] (0.025)

注：1. 所有收益率与 Alpha 值均已百分化；

2. 所有 t 值计算使用 Newy-West 标准误；

3. * $p < 0.1$, ** $p < 0.05$, *** $p < 0.01$ 。

总体而言，预期共识因子具有显著的正向定价效应，即个股 MA 水平越高，其未来的股票收益越高，验证了因子的投资价值与定价能力。

4.2.2 Fama-MacBeth 回归

在进行投资组合分析后，使用 Fama-MacBeth 回归（后文简称 FM 回归），探究 MA 因子对于未来收益的影响。做法为，对于每一个年月截面数据，使用回归模型：

$$\begin{aligned} return_{i,t+1} = & a_t + b_{1,t}MA_{i,t} + b_{2,t}beta_{i,t} + b_{3,t}ln_market_value_{i,t} + \\ & + b_{4,t}bm_ratio_{i,t} + b_{5,t}gross_margin_{i,t} + b_{6,t}investment_ratio_{i,t} + \epsilon_{i,t} \end{aligned}$$

求出各个变量的系数序列，计算其均值，并进行 t 检验。在计算 t 值时，使用 Newy-West 标准误。结果如表 4.4 所示。

表 4.4 Fama-MacBeth 回归结果

变量	无控制变量	3 控制变量	5 控制变量
MA	0.123*** [12.240] (0.000)	0.139*** [14.480] (0.000)	0.139*** [14.440] (0.000)
beta		-0.003 [-1.329] (0.184)	-0.004 [-1.438] (0.150)
对数流通市值		0.006*** [4.834] (0.000)	0.006*** [4.894] (0.000)
账面市值比		-0.019*** [-4.826] (0.000)	-0.022*** [-5.582] (0.000)
毛利率			-0.009*** [-3.536] (0.000)
投资比率			-0.002 [-0.394] (0.693)
常数项	-0.075*** [-10.850] (0.000)	-0.155*** [-7.111] (0.000)	-0.148*** [-6.372] (0.000)
观测数	241	241	241

1. $p < 0.1$, $**p < 0.05$, $***p < 0.01$;

2. t 值计算使用 Newy-West 标准误。

其中，第 2 列表示不引入控制变量，MA 因子的 FM 回归结果；第 3 列表示引入 beta, 对数市值，账面市值比三个月频控制变量后 FM 回归的结果；第 4 列

表示再引入毛利率和投资比率两个季频控制变量后 FM 回归的结果。从表中结果可知，MA 对未来收益率具有显著的正向影响，这一结论在控制了多个常见收益影响因素后仍然成立。

4.3 稳健性检验

为了验证实验结果的稳定性，本文进行了一系列稳健性检验，包括改变训练窗口、改变因子掩码长度、改变投资者数量。具体来说，分别将训练窗口设定为 6 个月，24 个月；将投资者数量设置为 15，45；将掩码长度设置为 45，75。然后分别进行分组检验和 Fama-MacBeth 回归。

由于篇幅限制，仅汇报对冲组合的收益、夏普比率、FF5- α 与 5 控制变量 FM 回归中 MA 因子结果。表 4.5 到 4.7 为改变投资者数量、窗口大小、掩码长度后的稳健性检验结果。其中，第 2 到 4 列展示的是对冲组合的平均收益、夏普比率、FF5- α 第 5 列展示的是控制了 beta，对数市值，账面市值比，毛利率，投资比率五个控制变量后的 FM 回归结果。结果中还汇报了使用 Newey-West 标准误后 t 值和 p 值。

表 4.5 稳健性检验结果-投资者数量

投资者数量	平均收益	夏普比率	FF5 Alpha	FM 回归
15	0.230*** [2.312] (0.008)	22.13	0.209*** [2.612] (0.007)	0.131*** [16.507] (0.000)
45	0.342*** [4.102] (0.000)	31.25	0.231*** [2.312] (0.007)	0.231*** [2.312] (0.000)

表 4.6 稳健性检验结果-窗口大小

窗口大小	平均收益	夏普比率	FF5 Alpha	FM 回归
6	0.172** [1.548] (0.041)	15.52	0.114* [1.201] (0.070)	0.093*** [8.724] (0.000)
24	0.192*** [4.241] (0.000)	19.85	0.173*** [3.123] (0.000)	0.031*** [13.312] (0.000)

表 4.7 稳健性检验结果-因子掩码长度

因子掩码长度	平均收益	夏普比率	FF5 Alpha	FM 回归
45	0.323*** [5.312] (0.000)	33.31	0.245*** [3.062] (0.000)	0.244*** [15.312] (0.000)
75	0.195*** [1.917] (0.000)	25.45	0.196*** [2.729] (0.000)	0.281*** [11.312] (0.000)

检验结果显示，核心结论未随参数调整发生改变，具备良好稳健性。调整投资者数量为 15、45 时，两组对冲组合平均收益、FF5- α 及 FM 回归 MA 因子系数均在 1% 水平下显著，夏普比率分别维持 22.13、31.25，收益表现稳健；改变训练窗口为 6 个月、24 个月，组合收益均显著为正，短窗口下收益边际显著、长窗口下高度显著，FM 回归系数始终保持 1% 水平显著；调整因子掩码长度为 45、75，两组组合核心指标均高度显著，夏普比率分别为 33.31、25.45，收益幅度略有波动但显著性不变。所有结果均经 Newey-West 标准误调整，核心指标均显著为正，证明 MA 因子收益与定价能力不依赖特定参数设定。

5 进一步研究

5.1 预期共识定价效应的机制分析

本节将通过实验金融的方式,分析预期共识定价效应的形成机制。根据 Miller 的假说^[30],当投资者面临卖空约束时,悲观投资者无法通过卖空交易充分表达其负面预期,资产价格将主要由乐观投资者的信念决定;投资者预期分歧越大,预期共识越低,股价被乐观预期高估的程度就越严重。唐国豪等学者^[17]使用多个神经网络模型,模拟异质性个体投资者的预期,并且通过融券可行性和机构投资者持股比例,来检验融券可行性在预期共识定价效应中的作用。研究发现,融券可行的证券,其预期共识定价效应不显著,而融券不可行的证券,其预期共识定价效应显著。该研究表明,融券可行性是预期共识定价效应的重要形成机制。

本文将使用实验金融的方式来研究融券可行性在预期共识定价效应中的作用。具体来说,在基准模型中,约定了不允许融资融券,即对于任何一个神经网络的输出,进行截断,使得输出为非负数。

5.1.1 放松融资融券约束

在本节,对该约束进行放松,允许 Agent 进行融资和融券。具体来说,对于最终决策:

$$\vec{action}_{a,portfolio,t} = (w_1, w_2, \dots, w_{n+1})$$

决策需要满足约束:

1) 权重之和为 1, 即 $\sum_{i=1}^{n+1} w_i = 1$;

2) 允许 w_i 为负数, 当 $w_i < 0, i \neq n+1$ 时, 表示做空证券 i , 获取总资金的 $|w_i|$ 倍的资金; 如果 $w_{n+1} < 0$, 表示借入资金购买证券, 获取总资金的 $|w_{n+1}|$ 倍的资金; 为了避免无限制的融资融券, 设定一个最大杠杆率 $L_{max} \geq 0$, 使得:

$$\sum_{i=1}^{n+1} |w_i| \cdot I(w_i < 0) \leq L_{max}$$

其中, $I(x)$ 为指示函数, 当 x 为真时, 取 1, 否则取 0。

由于使用 Tanh 作为激活函数, 输出 o_i 范围为 $(-1, 1)$, 因此, 为了满足上述约束, 需要对 o_i 进行归一化处理, 具体来说:

1. 计算所有小于 0 的 o_i 的绝对值之和 S ，即：

$$S = \sum_{i=1}^n |o_i| \cdot I(o_i < 0)$$

如果 $S > L_{max}$ ，则按照 $\frac{L_{max}}{S}$ 的比例，缩小所有小于 0 的 o_i ：

$$o_i^{norm} = o_i \cdot \frac{L_{max}}{S} \quad \text{if } o_i < 0$$

否则，不变，即：

$$o_i^{norm} = o_i \quad \text{if } o_i < 0$$

2. 将所有大于 0 的 o_i 归一化，使得其和为 $1 + L_{max}$ ，即：

$$o_i^{norm} = o_i \cdot \frac{1 + L_{max}}{\sum_{i=1}^n o_i} \quad \text{if } o_i \geq 0$$

3. 归一化后的输出记作：

$$\mathbf{o}_{a,portfolio,t}^{norm} = (o_1^{norm}, o_2^{norm}, \dots, o_{n+1}^{norm})$$

4. 归一化后的输出就是最终的决策向量，记作：

$$\vec{action}_{a,portfolio,t} = (w_1, w_2, \dots, w_{n+1})$$

其中， $w_i = o_i^{norm}$ 。

5.1.2 实验结果

分别设定融资融券约束 $L_{max} = 0.25, 0.5$ ，再进行实验，对于结果进行分组检验和 Fama-MacBeth 回归。由于篇幅限制，仅展示对冲组合的平均收益、夏普比率、FF5- α 与 5 控制变量 FM 回归结果。结果如表 5.1 所示。

表 5.1 机制分析

融资融券上限	平均收益	夏普比率	FF5 Alpha	FM 回归
0	0.380*** [4.045] (0.000)	26.840	0.207*** [2.247] (0.000)	0.139*** [14.440] (0.000)
0.25	0.063* [1.120] (0.064)	12.562	0.083* [0.949] (0.072)	0.013** [1.570] (0.035)
0.5	0.001 [0.312] (0.297)	6.248	0.002 [0.412] (0.424)	0.063* [1.002] (0.051)

从表中结果可见，融资融券约束松紧与预期共识定价效应直接相关，约束越宽松，定价效应越弱。融资融券上限为 0 的严格约束下，对冲组合平均收益 0.380、FF5- α 及 FM 回归系数均在 1% 水平高度显著，夏普比率达 26.840%，定价效应极强；约束放松至 0.25 时，组合收益大幅回落，平均收益仅 0.063（10% 水平边际显著），夏普比率降至 12.562，各项指标显著性同步弱化；约束进一步放宽至 0.5 后，超额收益近乎消失，平均收益无统计显著性，FF5- α 不再显著，仅 FM 回归系数勉强维持 10% 水平显著。整体而言，随着融资融券限制放松，组合收益、夏普比率及回归显著性均大幅下滑，说明约束收紧时投资者难以充分交易修正预期，催生预期共识定价效应，约束放松则该效应显著弱化，由此证实融资融券限制是预期共识定价效应的重要形成机制。

随着融资融券限制的放松，对冲组合的平均收益和夏普比率明显下降，FF5- α 和 FM 回归的显著性也明显下降。该结果表明，随着融资融券的放松，投资者可以更容易的表达其预期，从而修正了预期共识的定价效应，导致预期共识的定价效应不显著。因此，融资融券限制是预期共识定价效应的重要形成机制。

5.2 异质性分析

按照市值、企业产权性质和股市周期三个维度，检验结论的异质性。具体来说：第一，每一个月份，对企业的市值进行排序，按照是否大于中位数，划分为大市值与小市值两组；第二，按照是否为国有企业，划分为非国有企业与国有企业两组；第三，参考 Maheu 和 McCurdy 的方法^[52]，使用沪深 300 指数，划分每一个月份为牛市或熊市周期。其具体做法是，将股市变动视作一个马尔可夫过程，使用最大似然估计方法，估计出牛市和熊市状态的转移概率矩阵，并根据转移概率矩阵，划分每一个月份为牛市或熊市周期。

在按照异质性分组后，每一组内部，再将观测按各自预期共识水平划分为 5 个分组，保持 $2 \times 5 = 10$ 个分组。在每个分组内部，分别进行分组检验和 Fama-MacBeth 回归。

由于篇幅限制，仅展示对冲组合的平均收益、夏普比率、FF5- α 与 5 控制变量 FM 回归结果。

5.2.1 基于企业市值的异质性分析

为考察预期共识效应在不同市值股票中的表现差异，本文将样本按市值高低划分为大市值与小市值两组，分别进行分组检验与 Fama-MacBeth 回归，结果如表 5.2 所示。

表 5.2 基于企业市值的异质性分析

市值	平均收益	夏普比率	FF5 Alpha	FM 回归
大市值	0.589*** [4.913] (0.000)	33.120	0.406*** [3.427] (0.001)	0.126*** [14.450] (0.001)
小市值	1.216*** [9.613] (0.000)	98.380	1.094*** [8.686] (0.000)	0.154*** [12.270] (0.000)

从分组检验结果来看，预期共识效应在大市值与小市值样本中均显著成立。在大市值样本中，平均收益率随组合呈现单调递增趋势，对冲组合的平均收益率为 0.589%，在 1% 水平上显著，对应的 CAPM- α 、FF3- α 与 FF5- α 均在 1% 水平上显著为正。

在小市值样本中，预期共识的定价效应更为突出：对冲组合的平均收益率高达 1.216%，在 1% 水平上显著，对应的 CAPM- α 、FF3- α 与 FF5- α 均在 1% 水平上显著为正，且其数值远超大市值样本。同时，小市值对冲组合的夏普比率为 98.380%，也显著高于大市值样本的 33.120%，表明小市值中预期共识策略的收益风险比更优。

Fama-MacBeth 回归结果进一步验证了上述结论。在大市值样本中，无论是否加入控制变量，预期共识指标 MA 的回归系数均在 1% 水平上显著为正：在加入 5 个控制变量后，MA 系数仍为 0.126。在小市值样本中，MA 的回归系数同样在 1% 水平上显著为正，且数值明显更大：加入 5 个控制变量后为 0.154，表明预期共识对小市值股票收益的边际影响更强。

上述异质性结果可以从错误定价视角加以解释，核心逻辑为：小市值股票面临更严格的卖空约束和更严重的有限套利限制，使其错误定价程度更深，进而放大了预期共识的定价效应。大市值股票多为两融核心标的，卖空约束弱，价格高估空间有限；小市值股票普遍两融覆盖不足、券源稀缺，卖空约束极强，低共识

下悲观预期无法入市导致股价显著高估，高共识则对应理性定价，因此小市值高低共识组合的收益差异更突出。

5.2.2 股权性质异质性分析

为考察预期共识效应在不同股权性质企业中的表现差异，本文将样本划分为非国有企业与国有企业两组，分别进行分组检验与 Fama-MacBeth 回归，结果如表 5.3 所示。

表 5.3 股权性质异质性分析

股权性质	平均收益	夏普比率	FF5 Alpha	FM 回归
国有企业	0.313 [1.627] (0.104)	11.110	0.128 [0.714] (0.476)	0.111*** [14.900] (0.000)
非国有企业	0.907*** [7.326] (0.000)	55.480	0.711*** [5.869] (0.000)	0.151*** [12.700] (0.000)

从分组检验结果来看，预期共识效应在非国有企业中表现显著，而在国有企业中明显弱化。在非国有企业样本中，平均收益率随组合呈现单调递增趋势：对冲组合的平均收益率高达 0.907%，在 1% 水平上显著，对应的 α 均在 1% 水平上显著为正。在国有企业样本中，尽管组合收益率从低到高有一定递增趋势，但对冲组合的平均收益率仅为 0.313%，且统计上不显著；对应的 α 也均不显著，表明国有企业中预期共识的定价效应在分组检验层面未得到充分体现。

Fama-MacBeth 回归结果进一步验证了上述结论。在非国有企业样本中，无论是否加入控制变量，预期共识指标 MA 的回归系数均在 1% 水平上显著为正：在加入 5 个控制变量后，MA 系数仍为 0.151。在国有企业样本中，MA 的回归系数虽仍在 1% 水平上显著为正，但数值明显更小：加入 5 个控制变量后为 0.111，表明预期共识对国有企业股票收益的边际影响更弱。

上述异质性结果可以从错误定价视角并结合国企与非国企的制度差异加以解释，核心逻辑为：非国企面临更严重的信息不对称且缺乏政府隐性背书，使其错误定价程度更深，进而放大了预期共识的定价效应。一方面，国企受监管更严格，信息披露规范、分析师覆盖充分，投资者信息不对称程度较低，预期共识的增量定价效应有限；非国企信息透明度偏低，预期共识作为市场对公司价值的认

可信号，其“定价锚”作用显著更强。另一方面，国企的政府信用背书带来股价估值刚性，天然压缩了错误定价空间；非国企缺乏此类背书，估值高度依赖市场对其经营成长的预期，分歧加剧时极易出现显著错误定价，进一步强化了预期共识的定价效应。

5.2.3 市场周期异质性分析

为考察预期共识效应在不同市场周期中的表现差异，分别进行分组检验与 Fama-MacBeth 回归，结果如表 5.4 所示。

表 5.4 市场周期异质性分析

市场周期	平均收益	夏普比率	FF5 Alpha	FM 回归
熊市	0.688	19.710	0.195	0.155***
	[1.548]		[0.461]	[9.924]
	(0.122)		(0.645)	(0.000)
牛市	0.511***	29.640	0.364**	0.132***
	[3.997]		[2.581]	[11.190]
	(0.000)		(0.010)	(0.000)

从分组检验结果来看，预期共识效应在牛市中表现显著，而在熊市中分组检验的显著性有所下降。在牛市样本中，平均收益率随组合呈现单调递增趋势：对冲组合（做多高预期共识组合、做空低预期共识组合）的平均收益率为 0.511%，在 1% 水平上显著，对应的 α 均在 1% 或 5% 水平上显著为正。在熊市样本中，尽管组合收益率从低到高有一定递增趋势，对冲组合的平均收益率为 0.688%，但统计上不显著；对应的 α 也均不显著。

Fama-MacBeth 回归结果进一步验证了预期共识效应在不同市场周期中的存在性。在牛市样本中，无论是否加入控制变量，预期共识指标 MA 的回归系数均在 1% 水平上显著为正：在加入 5 个控制变量后，MA 系数仍为 0.132。在熊市样本中，尽管仍然有显著的正向系数，但显著性有所下降。

上述异质性结果可以基于行为金融学中投资者情绪理论与错误定价理论加以解释，核心逻辑为：牛市中高涨的投资者情绪与卖空约束放大了错误定价，熊市中预期共识则发挥了更强的“安全信号”作用。具体而言：第一，牛市中投资者乐观情绪主导市场，低预期共识对应乐观投资者的极端预期，在卖空约束下悲观预期无法充分反映于价格，导致股价显著高估；高预期共识则对应更理性的定

价，因此高低共识组合的收益差异显著。第二，熊市中投资者风险厌恶程度大幅提升，预期共识成为验证公司价值与抗风险能力的强安全信号，而预期分歧大的股票更易被抛售，因此熊市中 MA 的边际定价效应更强。第三，A 股熊市中常伴随“救市”政策与“政策底”预期，部分低共识股票可能因政策刺激出现短期反弹，削弱了高低共识组合的收益差异，这是熊市分组检验显著性下降的重要原因。

6 结论与建议

本文通过构建多个 Agent 投资者，以 88 个因子数据作为输入，MLP 模型作为 Agent 的决策模型，二次效用函数作为奖励函数，PPO 算法作为强化学习训练方式，探究了 Agent 投资者的预期共识定价效应。实验的结果表明，投资者的预期共识度越高，股票的未来收益越高，这一结论在一系列稳健性检验后依然成立。进一步的，本文从融资和融券约束的角度，探讨了预期共识定价效应的形成机制。实验的结果表明，融资和融券约束是预期共识定价效应的重要形成机制，在放松融资和融券约束后，预期共识定价效应显著减弱。最后，本文从企业市值、股权异质性和市场周期的角度，分析了预期共识定价效应的异质性。实验的结果表明，小市值企业、非国企企业和牛市周期中的企业，其预期共识定价效应显著更高。上述研究揭示了在 A 股市场中，投资者的预期形成机制和市场定价机制，对于理解金融市场的运行规律和稳定性有着重要的意义。本文对政策和研究的启示如下：

第一，对投资者而言，达成预期共识的证券意味着更高的未来收益，因此，投资者应该关注其他投资者的预期，通过分散化资产，避免买入分歧较大的证券，以获得更高的未来收益。

第二，对于政策制定者而言，需要关注市场中投资者的预期，做到良性引导，避免形成预期共识的证券被过度炒作，导致市场泡沫化。同时，通过完善融资融券制度，允许投资者进行融资和融券，可以有效降低投资者的预期分歧，引导资产正确定价。

最后，对于研究者和金融监管机构而言，应当重视人工智能在金融领域的应用，通过构建投资者的方法，来系统地研究微观投资者的行为如何传导至宏观价格。在市场监管、信息披露等领域，也应当重视人工智能技术，提高监管效率和信息披露质量。

参考文献

- [1] GREENWOOD R, SHLEIFER A. Expectations of returns and expected returns [J]. The Review of Financial Studies, 2014, 27(3): 714-746.
- [2] JONES C M, SHI D, ZHANG X, et al. Retail trading and return predictability in china[J]. Journal of Financial and Quantitative Analysis, 2025, 60(1): 68-104.
- [3] 薛健, 汝毅. 信息披露业务关系与新闻报道质量[J]. 管理世界, 2020(10).
- [4] KUMAR A, LEE C M C. Retail investor sentiment and return comovements [J/OL]. The Journal of Finance, 2006, 61(5): 2451-2486. DOI: 10.1111/j.1540-6261.2006.01063.x.
- [5] 伍戈, 陈得文. 为什么预期稳定是重要的——兼议货币市场上的规则与相机抉择政策[J]. 金融监管研究, 2015(5): 38-50.
- [6] 洪永淼, 汪寿阳. 大数据如何改变经济学研究范式?[J]. 管理世界, 2021(10).
- [7] SHARPE W F. Capital asset prices: a theory of market equilibrium under conditions of risk[J]. The Journal of Finance, 1964, 19(3): 425-442.
- [8] FAMA E F, FRENCH K R. The cross-section of expected stock returns[J]. The Journal of Finance, 1992, 47(2): 427-465.
- [9] GU S, KELLY B T, XIU D. Empirical asset pricing via machine learning[J]. The Review of Financial Studies, 2020, 33(5): 2223-2273.
- [10] 李斌, 邵新月, 李玥阳. 机器学习驱动的基本面量化投资研究[J]. 中国工业经济, 2019(8).
- [11] 马甜, 姜富伟, 唐国豪. 深度学习与中国股票市场因子投资——基于生成式对抗网络方法[J]. 经济学 (季刊), 2022(3).
- [12] MINSKY M. Steps toward artificial intelligence[J/OL]. Proceedings of the IRE, 1961. DOI: 10.1109/JRPROC.1961.287775.

- [13] TURGUT Y, BOZDAG C E. A framework proposal for machine learning-driven agent-based models through a case study analysis[J/OL]. *Simulation Modelling Practice and Theory*, 2023, 123: 102707. DOI: 10.1016/j.simpat.2022.102707.
- [14] AHMED S, ALSHATER M M, EL AMMARI A, et al. Artificial intelligence and machine learning in finance: a bibliometric review[J/OL]. *Research in International Business and Finance*, 2022, 61: 101646. DOI: 10.1016/j.ribaf.2022.101646.
- [15] SHI S, LIU Y, ZHANG C, et al. XPM: an explainable deep reinforcement learning framework for portfolio management[C/OL]//*Proceedings of the 30th ACM International Conference on Big Data Analytics (ICBDA)*. ACM, 2021: 1245-1254. <https://doi.org/10.1145/3459637.3482348>.
- [16] LEE J, KIM R, YI S W, et al. MAPS: multi-agent reinforcement learning-based portfolio management system[A/OL]. *arXiv* (2020). <https://arxiv.org/abs/2007.05402>.
- [17] 唐国豪, 陈海玮, 朱琳, 等. 投资者预期协同的资产定价研究——基于多特征机器学习视角[J]. *管理世界*, 2025(12): 88-104.
- [18] LEMMON M, PORTNIAGUINA E. Consumer confidence and asset prices: some empirical evidence[J/OL]. *The Review of Financial Studies*, 2006, 19(4): 1499-1529. DOI: 10.1093/rfs/hhj038.
- [19] 朱宏泉, 余江, 陈林. 异质信念、卖空限制与股票收益——基于中国证券市场的分析[J]. *管理科学学报*, 2016, 19(7): 115-126.
- [20] 孟庆斌, 黄清华. 卖空机制是否降低了股价高估?——基于投资者异质信念的视角[J/OL]. *管理科学学报*, 2018, 21(4): 43-66. DOI: 10.3969/j.issn.1007-9807.2018.04.003.
- [21] DIETHER K B, MALLOY C J, SCHERBINA A. Differences of opinion and the cross section of stock returns[J/OL]. *The Journal of Finance*, 2002, 57(5): 2113-2141. DOI: 10.1111/1540-6261.00497.

- [22] ANDERSON E W, GHYSELS E, JUERGENS J L. Do heterogeneous beliefs matter for asset pricing?[J/OL]. The Review of Financial Studies, 2005, 18(3): 875-924. DOI: 10.1093/rfs/hhi017.
- [23] 伍燕然, 潘可, 胡松明, 等. 行业分析师盈利预测偏差的新解释[J/OL]. 金融研究, 2012, 4: 154-168. DOI: 10.3969/j.issn.1002-7246.2012.04.015.
- [24] 部慧, 解峥, 李佳鸿, 等. 基于股评的投资者情绪对股票市场的影响[J/OL]. 管理科学学报, 2018, 21(4): 1 16. DOI: 10.19920/j.cnki.jmsc.2018.04.001.
- [25] 万海远, 张尉, 陈基平, 等. 税收政策支持与企业预期转变[J/OL]. 经济研究, 2024, 59(4): 123-140. DOI: 10.16528/j.cnki.22-1054/f.202404123.
- [26] HORNIK K, STINCHCOMBE M, WHITE H. Multilayer feedforward networks are universal approximators[J]. Neural Networks, 1989, 2(5): 359-366.
- [27] SIMS C A. Implications of rational inattention[J]. Journal of Monetary Economics, 2003, 50(3): 665-690.
- [28] DANIEL K, HIRSHLEIFER D, SUBRAHMANYAM A. Investor psychology and security market under- and overreactions[J]. The Journal of Finance, 1998, 53(6): 1839-1885.
- [29] HONG H, STEIN J C. Disagreement and the stock market[J]. Journal of Economic Perspectives, 2007, 21(2): 109-128.
- [30] MILLER E M. Risk, uncertainty, and divergence of opinion[J/OL]. The Journal of Finance, 1977, 32(4): 1151-1168. DOI: 10.1111/j.1540-6261.1977.tb03317.x.
- [31] JOHNSON T C. Forecast dispersion and the cross section of expected returns [J/OL]. The Journal of Finance, 2004, 59(5): 1957-1978. DOI: 10.1111/j.1540-6261.2004.00691.x.
- [32] BOEHME R D, DANIELSEN B R, SORESCU S M. Short-sale constraints, differences of opinion, and overvaluation[J]. Journal of Financial and Quantitative Analysis, 2006, 41(2): 455-487.

- [33] PARK C. Stock return predictability and the dispersion in earnings forecasts[J]. The Journal of Business, 2005, 78(6): 2351-2376.
- [34] HENNING T, OJHA S M, SPOON R, et al. LLM agents do not replicate human market traders: evidence from experimental finance: arXiv:2502.15800[R/OL]. arxiv (2025). <https://arxiv.org/abs/2502.15800>. DOI: 10.48550/arXiv.2502.15800.
- [35] VIRATTT, CONTRIBUTORS. AI hedge fund: a multi-agent system for algorithmic trading[R/OL]. GitHub, 2025. <https://github.com/virattt/ai-hedge-fund>.
- [36] YANG Y, ZHANG Y, WU M, et al. TwinMarket: a scalable behavioral and social simulation for financial markets[C/OL]//NeurIPS: Vol. 39 The Thirty-ninth Annual Conference on Neural Information Processing Systems (NeurIPS). 2025. <https://arxiv.org/abs/2502.01506>. DOI: 10.48550/arXiv.2502.01506.
- [37] BAI Y, GAO Y, WAN R, et al. A review of reinforcement learning in financial applications[J/OL]. Annual Review of Statistics and Its Application, 2025, 12: 209-232. DOI: 10.1146/annurev-statistics-112723-034423.
- [38] QURESHI W, KADIA A, GOYAL A, et al. Deep learning vs. reinforcement learning in automated stock trading: a PRISMA-oriented systematic review[J/OL]. International Journal of Scientific and Advanced Technology (IJSAT), 2026, 17(1). DOI: 10.71079/IJSAT.2026.17101.
- [39] LIU X Y, YANG H, GAO J, et al. FinRL: deep reinforcement learning framework to automate trading in quantitative finance[A/OL]. arXiv (2021). <https://arxiv.org/abs/2111.09395>.
- [40] BALI T G, KELLY B T, MÖRKE M, et al. Machine forecast disagreement: w31583[Z]. National Bureau of Economic Research (NBER), 2023.
- [41] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [42] MOODY J E, WU L, LIAO Y, et al. Performance functions and reinforcement

- learning for trading systems and portfolios[J]. *Journal of Forecasting*, 1998, 17 (5-6): 441-466.
- [43] JIANG Z, XU D, LIANG J. A deep reinforcement learning framework for the financial portfolio management problem[A/OL]. *arXiv* (2017). <https://arxiv.org/abs/1706.10059>. DOI: 10.48550/arXiv.1706.10059.
- [44] MARKOWITZ H M. The optimization of a quadratic function subject to linear constraints[J/OL]. *Naval Research Logistics Quarterly*, 1956, 3(1-2): 111-133. DOI: 10.1002/nav.3800030110.
- [45] 尹海员, 李忠民. 个体特质、信息获取与风险态度——来自中国股民的调查分析[J]. *经济评论*, 2011, 2: 29-37.
- [46] 张玥. 中国股市投资者风险厌恶系数测算研究[J]. *福建质量管理*, 2019: 74-76,53.
- [47] JIANG L, NIU H, WANG H, et al. Dynamic implied risk aversion term structure: an empirical analysis based on shanghai stock exchange 50 ETF option[J/OL]. *Mathematical Problems in Engineering*, 2023, 2023: 9917375. DOI: 10.1155/2023/9917375.
- [48] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[A/OL]. *arXiv* (2017). <https://arxiv.org/abs/1707.06347>. DOI: 10.48550/arXiv.1707.06347.
- [49] RAFFIN A, HILL A, GLEAVE A, et al. Stable-Baselines3: reliable reinforcement learning implementations[J/OL]. *Journal of Machine Learning Research*, 2021, 22 (268): 1-8. <http://jmlr.org/papers/v22/20-1284.html>.
- [50] HONG H, SRAER D A. Speculative betas[J]. *The Journal of Finance*, 2016, 71 (5): 2095-2141.
- [51] BANERJEE S. Learning from prices and the dispersion in beliefs[J]. *The Review of Financial Studies*, 2011, 24(9): 3025-3068.

- [52] MAHEU J M, MCCURDY T H. Identifying bull and bear markets in stock returns
[J]. Journal of Business & Economic Statistics, 2000, 18(1): 100-112.

致谢

时光荏苒，本论文的完成，标志着我大学学习生涯即将告一段落。在此，我谨向所有给予我指导、帮助与支持的老师、同学和家人致以最诚挚的谢意。

首先，感谢我的指导老师李斌，本文的完成离不开老师在选题、框架和细节上的指导。李老师提供的因子库也是本文最重要的数据源。

我也感谢我的好友梁庭威和表弟颜玮城，他们提供的设备支持对于完成实验至关重要。

感谢所有设备，它们分别是：华硕主机 UNFEP0P 和三台联想拯救者系列，以及所有的容器。

最后，我要特别感谢我的家人。他们一直是我坚实的后盾，给予我无私的关爱、理解与支持，让我能够安心完成学业。由于本人学识有限，文中难免存在疏漏与不足之处，恳请各位老师批评指正。

附录 A 因子说明

本文使用了李斌等学者^[10]针对中国 A 股市场系统性梳理与构建的 96 个定价因子库，由于数据可得性问题，本文最终使用其中 88 个因子，具体因子列表见表A.1。

表 A.1 因子信息表

因子名称	因子类别	因子构造方式	因子时间范围	因子频率
mom36 36 个月动量	动量因子	t 月份的 36 个月动量因子等于 t-36 月份末到 t-13 月份末的累计日收益率	t-36 月份末到 t-13 月份末	每月一次
grCAPX 资本支出变化	成长因子	当期与前年当期资本支出的百分比变化	当期与前年当期	每年 3 次（5 月、9 月、11 月根据财报更新）
grltnoa 净经营性资产的增长率	成长因子	长期净经营性资产的增长率（净经营性资产 = 经营性资产 - 经营性负债）	年报/半年报/季报对应周期	每年 3 次（5 月、9 月、11 月根据财报更新）
vol 总波动率	交易摩擦因子	t 月内个股日收益率的标准差	t 月内（至少 10 个交易日）	每月一次
idvol 特定波动率	交易摩擦因子	将股票日收益率对市场等权重投资组合日收益率进行回归，所得残差的标准差；回归数据时间跨度为 t-11 月初到 t 月末	t-11 月初到 t 月末（至少 120 个交易日）	每月一次
pchcapx_ia 行业调整的资本支出变化	成长因子	上市公司资本支出变化减去公司所在行业资本支出变化（行业分类参考证监会 2010 版）	当期与前年当期	每年 3 次（5 月、9 月、11 月根据财报更新）
pa 利润资产比率	盈利因子	总利润除以滞后一年的总资产	当期与滞后一年	每年 3 次（5 月、9 月、11 月根据财报更新）
rd_mve 研发支出市值比	成长因子	管理费用除以 A 股流通市值（中国上市公司以管理费用代替研发费用）	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-7 月、8-9 月、10 月-次年 4 月使用对应数据）
rsup 意外收入	盈利因子	营业收入与 4 个月前营业收入之差除以当月末市值	去年 12 月底（对应 4 个月前为去年 8 月底）、今年 6 月底（对应 4 个月前为今年 2 月底）、今年 9 月底（对应 4 个月前为今年 5 月底）	每季度一次（5-8 月、9-10 月、11 月-次年 4 月分别使用对应数据）
lev 总负债市值比	价值因子	总负债除以 A 股流通市值	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-7 月、8-9 月、10 月-次年 4 月使用对应数据）
am 总资产市值比	价值因子	总资产合计除以 A 股流通市值	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-7 月、8-9 月、10 月-次年 4 月使用对应数据）

表 A.1 因子信息表（续）

因子名称	因子类别	因子构造方式	因子时间范围	因子频率
sfe 收益预测	盈利因子	分析师预测净利润均值除以每月末股价	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-8 月、9-10 月、11 月-次年 4 月使用对应数据)
OCFP 营业现金流价格比率	价值因子	t 月份末的营业现金流除以 t 月份末的 A 股流通市值	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-7 月、8-9 月、10 月-次年 4 月使用对应数据)
invgt 存货增长率	成长因子	t 月份的净存货额减去 t-12 月份的净存货额，再除以 t-12 月份的净存货额	t 月份与 t-12 月份	每季度一次 (5-7 月、8-9 月、10 月-次年 4 月使用对应数据)
volumetd 交易额	交易摩擦因子	t-11 月初到 t 月末交易额取均值	t-11 月初到 t 月末 (至少 120 个交易日)	每月一次
taxchg 税收增长率	成长因子	t 月份的税收减去 t-12 月份的税收再除以 t-12 月份的税收	t 月份与 t-12 月份	每季度一次 (5-7 月、8-9 月、10 月-次年 4 月使用对应数据)
idskew 特定偏差	交易摩擦因子	将股票日收益率对市场等权重投资组合日收益率进行回归，所得残差的偏度；回归数据时间跨度为 t-11 月初到 t 月末	t-11 月初到 t 月末 (至少 120 个交易日)	每月一次
std_turn 交易换手率的波动率	交易摩擦因子	t 月内日换手率的标准差	t 月内 (至少 10 个交易日)	每月一次
CFP_ia 行业调整现金流价格比	价值因子	每只股票的 CFP 因子数据减去其所在行业所有股票 CFP 因子均值 (行业分类参考证监会 2012 版，去除金融类股票，共 18 个行业)	每月末	每月一次
realestate 不动产	成长因子	直接用固定资产代替	年报/半年报/三季报数据	每年 3 次 (5 月、9 月、11 月根据财报更新)
accpt 现时增值因子	成长因子	(利润总额减去营业现金流) 除以净利润	年报/半年报/三季报数据	每年 3 次 (5 月、9 月、11 月根据财报更新)
cp 收益价格比	价值因子	净利润除以 A 股流通市值	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-7 月、8-9 月、10 月-次年 4 月使用对应数据)
imom 异质性动量	动量因子	将股票日收益率对市场等权重投资组合日收益率进行回归，所得残差的和；回归数据时间跨度为 t-11 月初到 t 月末	t-11 月初到 t 月末 (至少 120 个交易日)	每月一次
qr 速动比率	财务流动性因子	(流动资产合计减去净存货额) 除以流动负债合计	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-8 月、9-10 月、11 月-次年 4 月使用对应数据)
CFP 现金流价格比率	价值因子	t 月份末的净现金流除以 t 月份末的 A 股流通市值	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-7 月、8-9 月、10 月-次年 4 月使用对应数据)

表 A.1 因子信息表（续）

因子名称	因子类别	因子构造方式	因子时间范围	因子频率
QRG 速动比率增长率	财务流动性因子	(t 月份的速动比率减去 t-12 月份的速动比率) 除以 t-12 月份的速动比率	t 月份与 t-12 月份	每季度一次 (5-8 月、 9-10 月、11 月-次年 4 月 使用对应数 据)
DP 股利价格比	价值因子	应付股利除以 A 股流通市值	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-7 月、8-9 月、10 月-次 年 4 月使用 对应数据)
illiq 非流动性风险	交易摩擦因子	(t-11 月初到 t 月末的每日收益率的绝对值除以 日交易金额) 的平均值, 再乘以 10 ⁶	t-11 月初到 t 月末	每月一次
pchdepr 折旧变化	成长因子	固定资产折旧环比变化率	年报/半年报/三季 报数据	每年 3 次 (5 月、9 月、11 月根据财报 更新)
chfeps 预期每股收益的变化	盈利因子	股票 EPS 减去预测 EPS 均值	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-8 月、 9-10 月、11 月-次年 4 月 使用对应数 据)
bveg 净资产增长率	成长因子	t 月份的净资产减去 t-12 月份的净资产再除以 t-12 月份的净资产	t 月份与 t-12 月份	每季度一次 (5-7 月、8-9 月、10 月-次 年 4 月使用 对应数据)
salecash 营业收入现金比	财务流动性因子	营业收入除以货币资金	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-8 月、 9-10 月、11 月-次年 4 月 使用对应数 据)
SP 营业收入价格比	价值因子	营业收入除以 A 股流通市值	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-7 月、8-9 月、10 月-次 年 4 月使用 对应数据)
mom6 6 个月动量	动量因子	t 月份的 6 个月动量因子等于 t-6 月份末到 t-1 月 份末的累计日收益率	t-6 月份末到 t-1 月 份末	每月一次
pchsaleinv 营业收入存货比增长率	财务流动性因子	(t 月份的营业收入存货比减去 t-12 月份的营业 收入存货比) 除以 t-12 月份的营业收入存货比	t 月份与 t-12 月份	每季度一次 (5-8 月、 9-10 月、11 月-次年 4 月 使用对应数 据)
CRG 流动比率增长率	财务流动性因子	(t 月份的流动比率减去 t-12 月份的流动比率) 除 以 t-12 月份的流动比率	t 月份与 t-12 月份	每季度一次 (5-8 月、 9-10 月、11 月-次年 4 月 使用对应数 据)
std_dvol 交易额波动率	交易摩擦因子	根据 Tarun Chordia and Anshuman (2001), t 月月 内交易额的标准差即为 t 期交易额波动率因子; 计算时要求至少有 10 个交易日数据, 计算出 t 月因子数据后按从大到小将股票分成十组, 下一 个月 (t+1) 计算各组股票投资组合月收益率及 第十组与第一组收益率之差作为因子收益率	t 月内 (至少 10 个 交易日)	每月一次 (每月月末重 构投资组合 并检测)

表 A.1 因子信息表（续）

因子名称	因子类别	因子构造方式	因子时间范围	因子频率
lg 负债增长率	成长因子	t 月份的总负债减去 t-12 月份的总负债再除以 t-12 月份的总负债	t 月份与 t-12 月份	每季度一次 (5-7 月、8-9 月、10 月-次年 4 月使用对应数据)
pchgm_pchsale 毛利率变动%-销售变动%	盈利因子	毛利率变动百分比减去营业收入变动百分比（毛利率变动百分比 = (t 月份毛利率 - (t-24 月份毛利率 + t-12 月份毛利率) / 2) / (t-24 月份毛利率 + t-12 月份毛利率) / 2)	t 月份、t-12 月份、t-24 月份	每季度一次 (5-8 月、9-10 月、11 月-次年 4 月使用对应数据)
ct 资本换手率	盈利因子	销售收入除以滞后一年的总资产	当期与滞后一年	每年 3 次（5 月、9 月、11 月根据财报更新）
cfdebt 现金流负债比率	财务流动性因子	净利润除以平均负债合计（t 月份平均负债为 t-12 月份和 t 月份的负债合计的平均值）	t 月份与 t-12 月份	每季度一次 (5-8 月、9-10 月、11 月-次年 4 月使用对应数据)
absacc 增值因子的绝对值	成长因子	增值因子取绝对值（增值 = 利润总额 - 营业现金流）	年报/半年报/三季度数据	每年 3 次（5 月、9 月、11 月根据财报更新）
invchg 存货变化	成长因子	存货净额的增长除以平均资产合计（存货净额的增长 = t 月份的净存货额 - t-12 月份的净存货额；平均资产合计 = t-12 月份和 t 月份的总资产平均值）	t 月份与 t-12 月份	每季度一次 (4-7 月、8-9 月、10 月-次年 3 月使用对应数据)
tang 偿债能力/总资产	财务流动性因子	(库存现金 + 0.715 * 应收账款 + 0.547 * 存货 + 0.535 * PPE) / 总资产	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-8 月、9-10 月、11 月-次年 4 月使用对应数据)
sg 营业收入增长率	成长因子	t 月份的营业收入减去 t-12 月份的营业收入再除以 t-12 月份的营业收入	t 月份与 t-12 月份	每季度一次 (5-7 月、8-9 月、10 月-次年 4 月使用对应数据)
fgr5yr 分析师预测每股收益	成长因子	最近可得的分析师预测 5 年内每股收益的增长率	分析师预测数据	无明确说明 (数据起始于 2000 年 5 月)
noa 净经营性资产	成长因子	(经营性资产 - 经营性负债) / 总资产；经营性资产 = 总资产 - 货币资金 - 短期投资净额；经营性负债 = 总资产 - 短期借款 - 长期借款 - 归属于母公司所有者权益合计 - 少数股东权益	年报/半年报/三季度数据	每年 3 次（5 月、9 月、11 月根据财报更新）
RDsale 研发成本收入比	成长因子	管理费用除以营业收入（中国上市公司以管理费用代替研发费用）	去年 12 月底/今年 6 月底/9 月底	每季度一次 (5-7 月、8-9 月、10 月-次年 4 月使用对应数据)
pmg 营业利润增长率	成长因子	t 月份的营业利润减去 t-12 月份的营业利润再除以 t-12 月份的营业利润	t 月份与 t-12 月份	每季度一次 (5-7 月、8-9 月、10 月-次年 4 月使用对应数据)

表 A.1 因子信息表（续）

因子名称	因子类别	因子构造方式	因子时间范围	因子频率
invest 投资	成长因子	资本支出变化加上存货变化	年报/半年报/三季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
turn 交易换手率	交易摩擦因子	t-11 月初到 t 月末换手率的平均值（换手率 = 日交易量/流通股数）	t-11 月初到 t 月末（至少 120 个交易日）	每月一次
saleinv 营业收入存货比	财务流动性因子	营业收入除以存货净额	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-8 月、9-10 月、11 月-次年 4 月使用对应数据）
bm 账面市值比	价值因子	（月末 A 股流通股数/总股数）× 所有者权益合计/A 股流通市值	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-7 月、8-9 月、10 月-次年 4 月使用对应数据）
pchsale_pchinv 销售收入变化减去存货变化	成长因子	销售收入变化减去存货变化	年报/半年报/三季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
coskew 共同偏态	交易摩擦因子	对 t-11 月初到 t 月末个股日收益率及等权重市场投资组合数据进行回归，市场投资组合收益率平方的系数即为共同偏态数值；回归模型： $r_{i,t} = \alpha_i + \beta_i * r_{m,t} + coskew * r_{m,t}^2 + \varepsilon_{i,t}$	t-11 月初到 t 月末（至少 120 个交易日）	每月一次
cinvest 资本投资	成长因子	固定资产净值除以营业收入，取三个季度的平均（简化计算）；原始公式： $CI_t = CE_{t-1} / (CE_{t-2} + CE_{t-3} + CE_{t-4}) - 1$ ，其中 CE_{t-1} = 资本支出/销售收入	年报/半年报/三季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
mom12 12 个月动量	动量因子	t 月份的 12 个月动量因子等于 t-12 月份末到 t-1 月份末的累计日收益率	t-12 月份末到 t-1 月份末	每月一次
betad Dimson 调整 beta	交易摩擦因子	t-11 月初到 t 月末个股日收益率同包含前后两天的市场投资组合日收益率的回归系数之和；回归模型： $r_{i,t} = \alpha_i + \beta_{i,1} * r_{m,t-1} + \beta_{i,2} * r_{m,t} + \beta_{i,3} * r_{m,t+1} + \varepsilon_{i,t}$ $\beta_{i,t}^D = \beta_{i,1} + \beta_{i,2} + \beta_{i,3}$	t-11 月初到 t 月末（至少 120 个交易日）	每月一次
cr 流动比率	财务流动性因子	流动资产合计除以流动负债合计	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-8 月、9-10 月、11 月-次年 4 月使用对应数据）
Hire 员工人数	成长因子	上市公司员工人数	年报/半年报/三季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
cash 现金资产比	盈利因子	现金及现金等价物除以总资产	年报/半年报/三季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
size 市值	交易摩擦因子	每 A 股流通市值	每月末	每月一次
cashpr 现金生产力	盈利因子	（A 股流通市值 + 长期负债-总资产）/货币资金	年报/半年报/三季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
chnanalyst 分析师人数变化	成长因子	本月分析师人数减去三个月之前的人数，空缺值填充为 0	本月与三个月前	每月一次

表 A.1 因子信息表（续）

因子名称	因子类别	因子构造方式	因子时间范围	因子频率
Sgr 销售增长	成长因子	销售收入的年同比增长率（销售收入用营业总收入代替）	年报/半年报/季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
pchsale_pchrect 销售收入变化减去应收账款变化	成长因子	销售收入变化减去应收账款变化	年报/半年报/季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
Lagretn 短期反转	动量因子	上个月的月收益率	上个月	每月一次
size_ia 行业调整市值	交易摩擦因子	每只股票的 A 股流通市值减去其所在行业所有股票 A 股流通市值均值（行业分类参考证监会 20		
nanalyst 涉及股票的分析师人数	成长因子	参与预测的分析师人数，空缺值填充为 0	分析师预测数据	无明确说明
operprof 营业利润率	盈利因子	（营业收入 + 其他业务收入 - 销售成本 - 财务费用 - 销售费用 - 管理费用）/ 股本	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-8 月、9-10 月、11 月-次年 4 月使用对应数据）
betasq 系统性风险的平方	交易摩擦因子	t 月系统性风险的平方（系统性风险根据 Fama and MacBeth (1973) 计算）	t 月（基于 t-11 月初到 t 月末数据）	每月一次
beta 系统性风险	交易摩擦因子	t-11 月初到 t 月末个股日收益率同等权重市场投资组合的日收益率回归系数	t-11 月初到 t 月末（至少 120 个交易日）	每月一次
pchsale_pchxsga 销售收入变化减去三费变化	成长因子	销售收入变化减去管理费用、销售费用和财务费用总和的变化	年报/半年报/季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
salerec 营业收入应收账款比	财务流动性因子	营业收入除以应收账款	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-8 月、9-10 月、11 月-次年 4 月使用对应数据）
stdacc 增值因子的波动率	成长因子	增值因子过去 4 年的波动率（增值 = 利润总额 - 营业现金流）	过去 4 年财报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
nincr 收入增加期数	盈利因子	相比去年同期，净利润连续增加的期数（最大为 8，月度计数）	月度净利润数据	每月一次
roic 投入资本回报	盈利因子	营业收入除以投资资本的账面价值（分母 = 负债 + 所有者权益 - 货币资金）	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-8 月、9-10 月、11 月-次年 4 月使用对应数据）
roa 总资产收益率	盈利因子	净利润除以总资产	年报/半年报/季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
bm_ia 行业调整账面市值比	价值因子	每只股票的 BM 因子数据减去其所在行业所有股票 BM 因子均值（行业分类参考证监会 2012 版，去除金融类股票，共 18 个行业）	每月末	每月一次

表 A.1 因子信息表（续）

因子名称	因子类别	因子构造方式	因子时间范围	因子频率
ag 总资产增长率	成长因子	t 月份的总资产减去 t-12 月份的总资产再除以 t-12 月份的总资产	t 月份与 t-12 月份	每季度一次（5-7 月、8-9 月、10 月-次年 4 月使用对应数据）
roe 净资产收益率	盈利因子	净利润除以总资本	年报/半年报/季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
skew 总偏态	交易摩擦因子	t-12 月份末到 t 月份末（过去一年）的股票日收益率的偏态	t-12 月份末到 t 月份末（至少 120 个交易日）	每月一次
momchg 动量变化	动量因子	t 月份的动量变化等于 t-7 月份末到 t-1 月份末的动量减去 t-12 月份末到 t-7 月份末的动量	t-12 月份末到 t-1 月份末	每月一次
acc 增值因子	成长因子	增值除以平均资产合计； = $(\Delta CA - \Delta Cash) - (\Delta CL - \Delta STD - \Delta TP) - Dep$ ， 简化为利润总额-营业现金流；平均资产合计 = t-12 月份和 t 月份的总资产平均值	年报/半年报/季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）
ATO 总资产周转率	盈利因子	营业收入除以 NOA（净经营资产）	去年 12 月底/今年 6 月底/9 月底	每季度一次（5-8 月、9-10 月、11 月-次年 4 月使用对应数据）
LM 标准化换手率	交易摩擦因子	$LM = (Nozd + 1 / (\text{turnover} * \text{Deflator})) * 21 / NoTD$; 其中 Nozd 为 t 月交易量为 0 的交易日数目， NoTD 为 t 月交易日数目，turnover 为 t 月日交易 换手率之和，Deflator=480000	t 月内	每月一次
SgINVg 营业收入与存货增长率的差	成长因子	营业收入增长率减去存货增长率	t 月份与 t-12 月份	每季度一次（5-7 月、8-9 月、10 月-次年 4 月使用对应数据）
depr 折旧率	成长因子	固定资产折旧除以固定资产净值	年报/半年报/季报数据	每年 3 次（5 月、9 月、11 月根据财报更新）

附录 B 系统设计

本研究涉及较长的数据周期，较多的 Agent 和数量庞大的因子数据，如果仅依赖单进程/本地数据，全量加载数据，需要极大的资源开销和运算时间。

为了解决训练问题，依照论文需要，设计了一个基于“数据流水线”和“分布式训练”的计算集群。

B.1 系统架构

整体计算集群的架构如图B.1所示。




图 B.1 系统架构

B.1.1 总体架构设计

本研究构建了一个分布式多 Agent 强化学习训练平台，用于大规模投资组合优化实验。系统采用主从分布式架构，由中央控制节点、代理节点集群和数据存储系统组成，如图 B.1所示。系统设计的核心思想是”数据流水线”与”分布式训练”的有机结合：数据流水线负责数据的预加载、清洗和缓存管理，确保训练过

程中数据的高效访问；分布式训练则通过容器化部署实现计算资源的弹性扩展和并行训练能力的提升。

B.1.2 中央控制节点

中央控制节点（Master）是整个系统的核心控制单元，承担着多重关键职能。它负责实验任务调度，根据实验配置生成训练任务，并采用负载均衡策略将任务分配给各个代理节点，确保计算资源的充分利用。同时，它还提供数据服务，维护数据库，为代理节点提供标准化后的特征数据。此外，中央节点还承担结果收集与分析的职能，进行性能统计、风险指标计算和可视化分析，支持实时监控训练进度和系统状态。最后，中央节点负责系统监控与容错，实时监控各节点的运行状态，自动检测并处理节点故障，确保系统的稳定性和可靠性。

B.1.3 系统组件

代理节点集群由多个 Docker 容器化的训练节点组成，每个节点独立运行强化学习训练任务。节点采用多进程架构，同时运行 TCP 监听进程、FRP 通信客户端和训练工作进程，通过 Docker 容器实现计算资源隔离。

系统数据采用层次化存储结构：其中，数据库负责存储因子数据、收益数据、证券信息等原始数据；而结果仓库负责接收节点回传的训练结果，用于后续的分析。

系统采用分层网络通信架构：使用 FRP 反向代理解决 NAT 穿透问题，建立稳定的通信隧道，实现节点与中央控制节点的通信。FRP（Fast Reverse Proxy）是一个开源的反向代理工具，可以通过访问公网服务器，通过建立通信隧道，将数据转发到内网服务器，实现 NAT 穿透。在建立通信隧道后，中央节点可以通过 TCP 协议，向训练节点发送启动、查询、停止控制信号；训练节点能够访问中央节点的 redis 缓存，获取标准化后的因子数据，使用 rsync 协议，向中央节点回传训练结果。

B.1.4 系统工作流程




图 B.2 工作流程

如图 B.2所示，系统的工作流程遵循标准化的执行步骤。首先是任务初始化阶段，中央节点根据实验配置生成任务参数，通过 FRP 隧道安全分发到各代理

节点。然后，中央节点启动数据流水线，不断加载训练数据，进行标准化处理，并保存到 redis 缓存中；节点启动后，不断获取 redis 缓存中的标准化因子数据，进行训练，并回传训练结果到中央节点。

B.2 数据流水线

数据流水线是中央系统的核心组件，采用事件驱动架构和 Redis 中间件，主要实现两个关键功能：**1)** 分批次数据加载，有效控制内存占用；**2)** 实现预加载机制，保证训练过程的数据连续供应，避免训练节点受阻塞。

B.2.1 消息流

数据流水线采用事件驱动的异步通信架构，通过消息总线实现各组件间的松耦合协作。其工作流程如图 B.3 所示。




图 B.3 数据流水线工作流程

其中，各个组件的具体功能为：

表 B.1 数据流水线核心组件功能说明

组件名称	功能描述
消息总线 (MessageBus)	系统的通信枢纽，采用发布-订阅模式协调各组件。支持异步事件路由，确保组件间的松耦合通信。
监控器 (Monitor)	系统的调度中枢，持续监控数据状态。维护数据片访问计数器，智能触发数据加载请求。执行双重监控：数量充足性和过期状态检查。
数据库读取器 (DBLoader)	数据获取组件，按时间窗口批量加载因子数据。执行数据格式转换，确保与后续处理环节的兼容性。
更新器 (Updater)	数据预处理组件，执行标准化和数据分片操作。将原始数据转换为适合训练的标准化数据片。通过访问节点管理器信息，准确判断数据片访问完成状态。
数据缓存层 (Cache)	Redis 实现的分布式缓存，存储标准化数据片和节点状态信息。提供高性能数据访问，支持并发读写操作。
节点管理器 (NodeManager)	虽然不直接参与消息流，但持续监控各训练节点的保活状态。将活跃节点信息存储到 Redis，为更新器提供节点状态查询服务，支持数据片过期判断。

数据流水线的工作流程采用标准化的消息驱动模式，具体执行步骤如下：

1. 数据监控阶段

监控器持续监控 Redis 缓存中的数据片状态，包括两个维度：

数量监控：检查数据片总数（年数）是否低于预设阈值，确保训练过程的数据供应连续性；

过期检查：通过访问计数器判断数据片是否被所有活跃节点访问完毕，过期数据片需要及时清理。

当检测到数据不足时，监控器向消息总线发布 *LoadRequest* 事件。

2. 数据加载阶段

消息总线接收 *LoadRequest* 事件，路由至数据库读取器。

数据库读取器从数据库加载指定时间窗口的因子数据，转换为 *DataFrame* 格式，

临时存储到 Redis，并向消息总线发布 *DataLoaded* 事件。

3. 数据处理阶段

消息总线接收 *DataLoaded* 事件，路由至更新器。

更新器将因子-下期收益对齐，连接。

然后，执行 Z-Score 标准化和缺失值处理，

最后，按“年:月:证券代码”格式分割为数据片，存储到 Redis 缓存层。

4. 数据消费阶段

训练节点从 Redis 缓存获取所需的数据片进行模型训练。

每次数据访问操作后，对应数据片的计数器中记录该节点 ID。

当所有活跃的训练节点完成对某个数据片的访问后，该数据片被自动清理。

5. 循环控制

系统返回步骤 1，继续监控数据片数量，

形成持续的数据供应循环，确保训练过程的连续性。

B.3 训练节点

B.3.1 容器化部署环境

本系统使用 Docker 容器作为训练节点，保证训练环境的统一性和节点启动的可复用性，极大地减少了配置多 Agent 的复杂度。Docker 是一种易用的容器工具，可类比为微型虚拟机，能够实现独立的环境隔离。

具体来说，对于一个训练节点，使用 Docker 容器，其环境需要配备以下工具：

1. nvidia-cuda 工具，实现 GPU 训练
2. python3，用于执行具体训练代码
3. rsync，用于同步实验结果
4. 其他网络管理工具

使用华为云仓库的 cuda:12.1.0-cudnn8-runtime-ubuntu22.04 镜像，其中包含了 nvidia-cuda，和 python3 然后，在 Docker 配置中，安装 rsync 和其他网络工具。

容器配置完成后，需要启动入口。在容器入口中，启动 frp 服务，使得中央节点可以访问容器；ss 启动一个 TCP 监听进程，该进程持续监听中央节点经 frp 隧道转发的 TCP 连接，内含启动、查询、停止控制信号。接收启动控制信号后，容器会启动训练进程 (worker)，执行具体的训练、结果回传等任务；接收查询控制信号后，容器会返回当前训练状态、训练进度、训练结果等信息，编译中央节点汇总；接收停止控制信号后，容器会停止训练进程。

B.3.2 训练进程

训练进程是训练节点的核心组件，负责执行具体的训练任务。

训练进程包括三个主要模块：

表 B.2 训练进程核心模块功能说明

模块名称	功能描述
数据预加载模块	实现异步数据流水线，从 Redis 缓存预加载训练数据，维护访问计数器，避免训练过程阻塞。采用多层缓存策略，包括本地内存缓存和 Redis 分布式缓存。
模型训练模块	基于 PyTorch 和 Stable-Baselines3 框架，实现滚动窗口强化学习训练。从数据模块获取预处理数据，执行 Agent 训练，实时缓存训练状态和梯度信息。
结果同步模块	负责分布式训练结果的收集、格式化和同步。使用回调机制定期整理训练指标，以 JSONL 格式推送至主节点，确保数据一致性和容错性。

数据模块的实现参考数据流水线，由获取器（fetcher），监控器（monitor）和缓存（cache）组成。当训练模块需要数据时，会从缓存中获取，获取后清除该数据；监控器持续监控缓存中数据数量，不足则通过加载器加载数据。

训练模块使用 pytorch，Stable-Baselines3 框架，实现滚动窗口的强化学习。每一期训练后，会将结果进行缓存。

保存模块负责同步训练结果到主节点。使用 Stable-Baselines3 中的回调功能，每训练一年，收集一次结果缓存，整理为 jsonl 格式数据，使用 rsync 协议，推送到主节点，然后清理结果缓存。

通过上述框架，可以实现滚动窗口训练；清理逻辑则避免了训练结果大量占用内存的问题。

