

武汉大学

本科毕业论文（设计）

国家网络安全学院毕业论文（设计）
模板预览及使用指南

姓 名：	XXX
学 号：	XXX
专 业：	XX 专业
学 院：	XX 学院
指导教师：	XXX 职称

二〇二五年 X 月

原创性声明

本人郑重声明：所呈交的论文（设计），是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文（设计）不包含任何其他个人或集体已发表及撰写的研究成果。对本论文（设计）做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文（设计）工作过程中没有伪造数据等行为。若在本论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：

指导教师签名：

日 期：

年 月 日

版权使用授权书

本人完全了解武汉大学有权保留并向有关部门或机构送交本论文（设计）的复印件和电子版，允许本论文（设计）被查阅和借阅。本人授权武汉大学将本论文的全部或部分内容编入有关数据进行检索和传播，可以采用影印、缩印或扫描等复制手段保存和汇编本论文（设计）。

作者签名：

指导教师签名：

日 期：

年 月 日

摘 要

请使用中文分号“;”分割关键词!

[illegible]

关键词: 关键词 1; 关键词 2; 关键词 3

ABSTRACT

Please use English semicolon and space to separate key words.

This is abstract. This is abstract. This is abstract. This is abstract. This is abstract.
This is abstract. This is abstract. This is abstract. This is abstract. This is abstract. This
is abstract. This is abstract. This is abstract. This is abstract. This is abstract. This is
abstract. This is abstract. This is abstract. This is abstract.

Keywords: Key1; Key2; Key3

目 录

摘 要	I
ABSTRACT	II
1 引言	1
2 文献综述	3
2.1 公式的使用	3
2.2 插图的使用	3
2.3 表格的使用	4
2.3.1 普通表格	4
2.3.2 跨页表格	4
2.3.3 统计表格	5
2.4 列表的使用	5
2.4.1 有序列表	5
2.4.2 不计数列表	5
2.5 定理的使用	6
3 研究设计	7
3.1 模型设计	7
3.1.1 Agent 构建与训练	7
4 其它格式	15
4.1 代码	15
4.1.1 原始代码	15
4.1.2 代码高亮	15

4.1.3 算法描述/伪代码	15
4.2 绘图	16
4.3 写在最后	16
参考文献	17
致谢	19
附录 A 因子说明	20
附录 B 系统设计	21
B.1 系统架构	21
B.2 数据流水线	21
B.3 分布式训练	21

1 引言

金融市场是一个具有动态演化特征的复杂协调系统。其中，金融产品价格形成于个体在不确定性情境下做出的决策^[1]。长期以来，中国的股票市场以散户投资者为主，贡献了超 80% 的市场交易量^[2]。散户投资者对于证券的基本信息理解有限，导致形成预期偏差，对市场波动产生显著的影响^[3]。具体来说，散户投资者获取和分析信息的能力有限，也无法完全准确地理解信息的含义；此外，行为金融的研究表明，散户投资者易受情绪影响，形成行为偏差，例如羊群效应、过度自信等。然而，降低投资者的预期偏差，提高预期协同度，能否使金融产品的定价过程趋于理性，从而降低市场波动，这一课题仍然存在争议^{[4] [5]}。无论在现有的大量研究中^[6]，还是党的会议上，都强调了引导市场预期、维护资本市场预期稳定的重要性。因此，探究投资者的预期协同度对于资产定价的影响，对于维护资本市场预期稳定具有重要的理论价值与现实意义。

近年来，机器学习方法在经济、金融、管理等领域受到的重视程度日益提高^[7]。在资产定价领域，因子分析法^{[8] [9]}自诞生以来，被广泛应用于资产定价研究。而机器学习方式，以其数据驱动的特性和强大的非线性拟合能力，逐渐成为资产定价研究的热点。Gu, Kelly, Xiu 等学者^[10]通过对比包括随机森林、梯度提升树、感知机在内的 14 种机器学习方法，发现机器学习在挖掘高维公司特征的非线性关系方面具有显著优势，解释力远强于传统因子模型。在国内，李斌等学者^[11]基于 A 股因子，对比了神经网络、支持向量机等模型在 A 股收益预测中的表现，发现机器学习能够有效捕捉 A 股“壳价值”“政策敏感性特征”等特殊定价因素。马甜等学者^[12]将生成式对抗网络引入 A 股因子构建，缓解了因子的稀疏性问题，构建的深度学习复合因子 A 股市场的表现优于传统因子。因子是对公司信息的提取和抽象，而机器学习通过对于因子的非线性拟合，可以模拟投资者对于公司信息的非线性处理过程，从而更准确地预测资产价格。

人工智能技术的发展为金融研究提供了新的视角和工具。Minsky 在 1961 年首次提出了“Agent”的概念^[13]，将 Agent 定义为能够通过协商协作解决问题的智能个体”，强调其社会交互性、自主性两大核心特性。相比于传统机器学习用于预测、分类等任务，Agent 可以直接模拟投资者“端到端”的决策过程，即收

集信息、解读信息、决策、执行、反馈的完整过程^[14]。自 2015 年来，Agent-Based 金融研究数量迅速增加，覆盖了股票价格预测、投资组合管理、风险管理等多个领域^[15]。使用 AI-Agent 模拟投资者决策过程，可以更准确地模拟投资者的决策过程，对于投资者预期协同度的研究具有重要的理论价值与现实意义。

2 文献综述

2.1 公式的使用

在文中引用公式可以这么写： $a^2 + b^2 = c^2$ 这是勾股定理，他还可以表示为 $c = \sqrt{a^2 + b^2}$ ，还可以让公式单独一段并且加上编号。注意，公式前请不要空行。

$$\sin^2 \theta + \cos^2 \theta = 1 \quad (2.1)$$

还可以通过添加标签在正文中引用公式，如式（2.1）。

我们还可以轻松打出一个漂亮的矩阵：

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 11 & 22 & 33 & 44 \end{bmatrix} \times \begin{bmatrix} 22 & 24 \\ 32 & 34 \\ 42 & 44 \\ 52 & 54 \end{bmatrix} \quad (2.2)$$

或者多行对齐的公式：

$$\begin{aligned} f_1(x) &= (x + y)^2 \\ &= x^2 + 2xy + y^2 \end{aligned} \quad (2.3)$$

2.2 插图的使用

$\LaTeX$ 环境下可以使用常见的图片格式：JPEG、PNG、PDF、EPS 等。当然也可以使用 $\LaTeX$ 直接绘制矢量图形，可以参考 `pgf/tikz` 等包中的相关内容。需要注意的是，无论采用什么方式绘制图形，首先考虑的是图片的清晰程度以及图片的可理解性，过于不清晰的图片将可能会浪费很多时间。

图示例如下：



图 2.1 插图示例

`[htbp]`选项分别是此处、页顶、页底、独立一页。`[width=\textwidth]`让图片占满整行，或`[width=2cm]`直接设置宽度。可以随时在文中进行引用，如图 2.1，建议缩放时保持图像的宽高比不变。

2.3 表格的使用

表格的输入可能会比较麻烦，可以使用在线的工具，如 Tables Generator 能便捷的创建表格，也可以使用离线的工具，如 Excel2LaTeX 支持从 Excel 表格转换成 LaTeX 表格。LaTeX/Tables 上及 Tables in LaTeX 也有更多的示例能够参考。

2.3.1 普通表格

下面是一些普通表格的示例：

表 2.1 简单表格

我是	一只	普通
的	表格	呀

表 2.2 一般三线表

姓名	学号	性别
张三	001	男
李四	002	女

2.3.2 跨页表格

跨页表格常用于附录（把正文懒得放下的实验数据统统放在附录的表中），以下是一个跨页表格的示例：

表 2.3 跨页表格示例

1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6
1	0	5	1	2	3	4	5	6

2.3.3 统计表格

要创建占满整个文字宽度的表格需要使用到 `tabularx`，如不需要，使用 `tabular` 就行。引用表格与其它引用一样，只需要：表 2.4，统计表格一般是三线表形式。

表 2.4 统计数据表格

序号	年龄	身高	体重
1	14	156	42
2	16	158	45
3	14	162	48
4	15	163	50
平均	15	159.75	46.25

2.4 列表的使用

下面演示了创建有序及无序列表，如需其它样式，`LaTeX Lists` 上有更多的示例。

2.4.1 有序列表

这是一个计数的列表

1. 第一项
 - (a) 第一项中的第一项
 - (b) 第一项中的第二项
2. 第二项
 - (i) 第一项中的第一项
 - (ii) 第一项中的第二项
3. 第三项

2.4.2 不计数列表

这是一个不计数的列表

- 第一项
 - 第一项中的第一项

– 第一项中的第二项

- 第二项
- 第三项

2.5 定理的使用

定理 2.5.1 设向量 $\mathbf{a} \neq \mathbf{0}$ ，那么向量 $\mathbf{b}/\mathbf{a}$ 的充分必要条件是：存在唯一的实数 λ ，使 $\mathbf{b} = \lambda\mathbf{a}$ 。

定义 2.5.1 这是一条定义。

引理 2.5.1 这是一条引理。

推论 2.5.1 对数轴上任意一点 P ，轴上有向线段 $\vec{OP}$ 都可唯一地表示为点 P 的坐标与轴上单位向量 $\mathbf{e}_u$ 的乘积： $\vec{OP} = u\mathbf{e}_u$ 。

性质 2.5.1 这是一条性质。

例 2.5.1 这是一条例。

注 2.5.1 这是一条注。

3 研究设计

3.1 模型设计

对于一个 Agent 投资者，其决策和学习的过程可以分为以下几个步骤：

算法 1: Agent 投资者决策过程

Input: 特征数据

Result: 更新后的神经网络

- 1 特征数据 $\xrightarrow{\text{神经网络}}$ 投资决策 @;
 - 2 投资决策、收益数据 $\rightarrow$ 组合收益;
 - 3 组合收益序列 $\rightarrow$ 组合表现指标（如波动率、夏普比率、最大回撤等）;
 - 4 组合表现指标 $\rightarrow$ 奖励;
 - 5 奖励 $\rightarrow$ 更新后的神经网络;
 - 6 重复上述步骤，直到达到预设的训练次数或达到预设的训练时间。
-

@同一过程可旁支用于计算 AED

根据上述步骤，可以设计一个 Agent 投资者的决策和学习过程。

3.1.1 数据输入

使用因子数据作为 Agent 投资者的输入，用于模拟投资者对于因子的解读和决策。因子数据是以年月-证券为主键的月度面板数据。记原始的因子数据为 $raw_factors_{a,s,t,i}$ ，表示第 a 个 Agent 在 t 月份对于证券 s 的因子 i 的原始值。

由于不同特征的量纲、数量级、分布等方面存在明显差异，因此需要对特征进行标准化处理，使得所有特征的均值为 0，标准差为 1。具体来说，记 N 为参与该月标准化的证券数量（如股票池大小）。对于每一个因子 $factor_{a,s,t,i}$ ，求相同月份所有证券的因子值的均值和标准差：

$$raw_mu_{t,i} = \frac{1}{N} \sum_{s=1}^N raw_factors_{a,s,t,i}$$

$$raw_sigma_{t,i} = \sqrt{\frac{1}{N} \sum_{s=1}^N (raw_factors_{a,s,t,i} - raw_mu_{t,i})^2}$$

然后对每一个因子进行标准化处理，得到标准化后的因子值：

$$factor_{a,s,t,i} = \frac{raw_factors_{a,s,t,i} - raw_μ_{t,i}}{raw_σ_{t,i}}$$

参考 FinRL^[16] 的设计，设定一个因子向量为：

$$\vec{factors}_{a,s,t} = (factor_{a,s,t,1}, factor_{a,s,t,2}, \dots, factor_{a,s,t,i}, \dots)^T$$

考虑到不同的 Agent 投资者的数据获取能力不同，对数据的关注程度也不同，因此，参考机器学习中的特征选择方法^[17]，设定 Agent_a 只能随机获取 88 个因子中的 l 个因子，用于分析决策。筛选后的因子向量为：

$$selected_factors_{a,s,t} = (factor_{a,s,t,random_1}, factor_{a,s,t,random_2}, \dots, factor_{a,s,t,random_i}, \dots)^T$$

其中 $random_i$ 为随机选择的因子索引，不同的 Agent 投资者选择的因子索引不同。

设定 Agent 拥有一定的数据回顾能力，可以回顾过去 m 个月的因子向量。在月份 t ，Agent 可以回顾过去 m 个月的因子向量，形成一个 (m, l) 的矩阵，记作：

$$factors_matrix_{a,s,t} = (factors_{a,s,t}, factors_{a,s,t-1}, \dots, factors_{a,s,t-m+1})$$

Agent 需要选择 n 只证券，构建一个投资组合，记作：

$$portfolio = (s_1, s_2, \dots, s_n)$$

将多个证券的因子矩阵拼接，可以得到一个三维张量，记作：

$$factors_tensor_{a,portfolio,t} = \begin{pmatrix} factors_matrix_{a,s_1,t} \\ factors_matrix_{a,s_2,t} \\ \vdots \\ factors_matrix_{a,s_n,t} \end{pmatrix}$$

其维度为 (n, m, l) 。

最后，Agent 可以回顾自己之前投资组合的收益情况，对于投资组合 $portfolio$ ，获取其 $t, t-1, t-2, \dots, t-m+1$ 月的收益，组成收益序列，记作：

$$returns_{a,portfolio,t} = (return_{a,portfolio,t-m+1}, return_{a,portfolio,t-m+2}, \dots, return_{a,portfolio,t})$$

其中， $return_{a,portfolio,t}$ 为使用 $t-1$ 月的决策构建投资组合 $portfolio$ 在 t 月份的收益。其计算方式为各个证券在 $t-1$ 月的决策水平其在 t 月份的收益水平的加权平均值。记 $w_{a,portfolio,t,s}$ 为第 a 个 Agent 在 t 月份对于证券 s 的决策权重，

$return_{s,t}$ 为证券 s 在 t 月份的收益，则：

$$return_{a,portfolio,t} = \sum_{s=1}^{n+1} w_{a,portfolio,t-1,s} \cdot return_{s,t}$$

其中， $w_{a,portfolio,t,n+1}$ 为现金权重，表示分配给无风险资产（现金）的比例，对应 $return_{n+1,t}$ 为无风险收益率。

该收益序列与具体证券无关，为组合整体收益。为与按证券组织的输入一致，将该收益序列复制 n 份，得到形状为 (n, m) 的矩阵（每行均为同一 m 维收益序列），记作：

$$\mathbf{returns_matrix}_{a,portfolio,t} = \begin{pmatrix} return_{a,portfolio,t-m+1} & return_{a,portfolio,t-m+2} & \dots & return_{a,portfolio,t} \\ return_{a,portfolio,t-m+1} & return_{a,portfolio,t-m+2} & \dots & return_{a,portfolio,t} \\ \vdots & \vdots & \vdots & \vdots \\ return_{a,portfolio,t-m+1} & return_{a,portfolio,t-m+2} & \dots & return_{a,portfolio,t} \end{pmatrix}$$

再将该矩阵在特征维上扩展为形状为 $(n, m, 1)$ 的三维张量，并与原有 (n, m, l) 张量在特征维上拼接，得到最终输入张量，其维度为 $(n, m, l+1)$ ，记作：

$$\mathbf{X}_{a,portfolio,t} = \begin{pmatrix} \mathbf{factors_matrix}_{a,s_1,t} \\ \mathbf{factors_matrix}_{a,s_2,t} \\ \vdots \\ \mathbf{factors_matrix}_{a,s_n,t} \\ \mathbf{returns_matrix}_{a,portfolio,t} \end{pmatrix}$$

3.1.2 神经网络

与预测模型不同，Agent 的神经网络采用端到端设计，无需预测组合未来的收益，而是直接进行决策，决定将多少比例的资金分配给每只证券（现金）。

(1) 数据输入层：参考 FinRL^[16]，采用多层感知机（MLP）作为 Agent 由观测到投资权重的映射模型。输入为前述的观测张量 $\mathbf{X}_{a,portfolio,t}$ ，形状为 $(n, m, l+1)$ 。

(2) 展平与线性层：将输入张量展平为一维向量，记作：

$$\mathbf{x} = \text{Flatten}(\mathbf{X}_{a,portfolio,t}) \quad \mathbf{x} \in \mathbb{R}^{nm(l+1)}$$

经过 Dropout 层后，得到：

$$\mathbf{x}' = \text{Dropout}(\mathbf{x}) \quad \mathbf{x}' \in \mathbb{R}^{nm(l+1)}$$

然后通过一层全连接层映射为 $n+1$ 维向量，记作：

$$\mathbf{z} = \mathbf{W}\mathbf{x}' + \mathbf{b} \quad \mathbf{W} \in \mathbb{R}^{(n+1) \times nm(l+1)}, \mathbf{b} \in \mathbb{R}^{n+1},$$

得到 $\mathbf{z} \in \mathbb{R}^{n+1}$ ，对应 n 只证券的权重及一个现金（无风险资产）维度。

(3) 激活函数：使用 Tanh 函数作为激活函数，将输出映射到 $(-1, 1)$ 之间。

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

经过 Tanh 函数激活后，得到模型输出，记作：

$$\mathbf{o}_{a, portfolio, t} = \tanh(\mathbf{z}) \quad \mathbf{o}_{a, portfolio, t} \in \mathbb{R}^{n+1}$$

使用 Tanh 作为激活函数，可以保留负权重，用于后续研究中放松对于杠杆和做空的限制。

(4) 输出归一化：按照决策的语义，Agent 的决策（行动）可以表示为一个和为 1 的向量，记作：

$$\vec{action}_{a, portfolio, t} = (w_1, w_2, \dots, w_{n+1}) \in \mathbb{R}^{n+1}$$

其中， w_i 表示分配给证券（现金） i 的比例。设定最后一个权重 w_{n+1} 为现金权重，表示分配给无风险资产（现金）的比例。

在基线回归中，设定不允许使用杠杆或者做空。因此，将 $\mathbf{o}_{a, portfolio, t}$ 转换为决策向量 $\vec{action}_{a, portfolio, t}$ ，需要满足以下约束：

1) 权重之和为 1，即 $\sum_{i=1}^{n+1} w_i = 1$ ，表示需要将全部资金用完，无用的资金需要分配给无风险资产（现金）；

2) 非负，即 $w_i \geq 0$ ，表示不允许做空证券，或者使用杠杆（即现金权重为负，表示借入资金购买证券）；

将 $\mathbf{o}_{a, portfolio, t}$ 记作：

$$\mathbf{o}_{a, portfolio, t} = (o_1, o_2, \dots, o_{n+1})$$

为了满足非负性约束，将 $\mathbf{o}_{a, portfolio, t}$ 中的负权重部分截断为 0，得到：

$$o_i^+ = \max(o_i, 0)$$

$$\mathbf{o}_{a, portfolio, t}^+ = (o_1^+, o_2^+, \dots, o_{n+1}^+)$$

然后进行简单归一化，得到归一化后的决策向量，记作：

$$\vec{action}_{a, portfolio, t} = \left(\frac{o_1^+}{\sum_{i=1}^{n+1} o_i^+}, \dots, \frac{o_{n+1}^+}{\sum_{i=1}^{n+1} o_i^+} \right)$$

3.1.3 奖励函数

在强化学习中,奖励函数是 Agent 用于评估其决策好坏,改进决策方向,实现模型优化的关键。参考 Moody 等^[2]和 jiang 等^[2]的研究,使用二次效用函数^[2]作为奖励函数。

$$u = \mu - \frac{A}{2}\sigma^2$$

具体来说,对于一个投资组合 $portfolio$,其在 t 月份的收益率为 $return_{a,portfolio,t}$ 。由于可能涉及采样算法,计算奖励前,需要再对 $action_{a,portfolio,t}$ 进行归一化。后续计算方式和前述相同。

Agent 在 t 时间点上决策,获取 $action_{a,portfolio,t}$,计算持有该组合到下一个时间点期间的收益 $return_{a,portfolio,t+1}$,作为期望收益 μ 。

再获取其前 m 个月的收益序列:

$$returns_{portfolio,t} = (return_{portfolio,t}, return_{portfolio,t-1}, \dots, return_{portfolio,t-m+1})$$

计算历史收益的样本均值:

$$\bar{r}_{portfolio,t} = \frac{1}{m} \sum_{i=0}^{m-1} return_{portfolio,t-i}$$

然后计算历史收益的方差:

$$\sigma^2 = \frac{1}{m} \sum_{i=0}^{m-1} (return_{portfolio,t-i} - \bar{r}_{portfolio,t})^2$$

参数 A 是风险厌恶系数。 A 越大,表明 Agent 越厌恶风险,越倾向于选择低风险的组合。根据尹海员等^[2]、张玥^[2]、jiang^[2]等学者的研究,在 A 股市场中,投资者的风险系数的取值范围在 $[2, 8]$ 之间,具有厚尾、右偏的分布特征。因此,使用对数正态分布采样 Agent 的风险厌恶系数。

$$\ln(A) \sim N(\mu_A, \sigma_A^2)$$

该分布具有恒正、右偏、厚尾的特征,符合投资者风险厌恶系数的分布特征。

3.1.4 强化学习

3.1.4.1 游戏设定

在本研究中，将投资组合决策建模为单步强化学习环境，每一次决策构成一局完整的游戏。在该设定下，Agent 在观测到因子数据后 obs 后，根据当前策略做出决策 $action$ ，并返回奖励 $reward$ 。 $reward$ 由二次效用函数计算得到，记作 $reward = (obs, action)$ 记每局对应一个转移 $(obs, action, reward)$ 。

强化学习的目标为，得到一个策略 π ，使得在观察到因子数据 obs 后，根据策略 π 做出的决策 $action$ ，能够最大化奖励 $reward$ 。

记策略 $\pi = \pi(action|obs)$ ，表示在 obs 观测下，做出决策 $action$ 的概率。则学习目标为：

$$J(\pi) = \mathbb{E}_{obs, action \sim \pi}[reward(obs, action)]$$

定义神经网络的参数为 θ ，则策略 π 可以表示为：

$$\pi_{\theta}(action|obs)$$

优化目标为：

$$J(\theta) = \mathbb{E}_{obs, action \sim \pi}[reward(obs, action)]$$

3.1.4.2 PPO 算法

使用近端策略优化（Proximal Policy Optimization, PPO）算法作为强化学习算法。PPO 策略由 Schulman 等^[7]提出，是一种基于策略梯度算法的强化学习算法。通过计算新的策略与当前策略的优势更新策略，并且通过限制概率比和裁剪的方式，避免策略更新幅度过大。该算法具有较好的收敛性和稳定性，适用于连续动作空间的问题。

使用 Stable-Baselines3(SB3)^[7]框架实现 PPO 算法。

(1) Actor-Critic 网络： PPO 使用 Actor-Critic 网络优化策略。Actor 网络用于生成策略，使用前述的神经网络 f 作为 Actor 网络。Actor 网络将 $f_{\theta}(obs)$ 映射为均值为 $f_{\theta}(obs)$ ，方差为 σ^2 的正态分布，在以这个分布作为策略 $\pi_{\theta}(action|obs)$ ，探索动作空间，记为：

$$\pi_{\theta}(action|obs) \sim \mathcal{N}(f_{\theta}(obs), \sigma^2)$$

价值函数 $V_\phi(obs)$ 用于评估当前策略的优劣势，其中， ϕ 为 Critic 网络的参数。用于拟合状态价值函数：

$$V^\pi(obs) = \mathbb{E}_{action \sim \pi(\cdot|obs)}[reward(obs, action)]$$

Critic 学习对上述期望的近似，即 $V_\phi(obs) \approx V^\pi(obs)$ ，作为基线，评估实际奖励 $reward$ 与期望奖励 $V^\pi(obs)$ 的差距：

$$\hat{A}(obs, action) = reward(obs, action) - V_\phi(obs)$$

通过不断训练，Critic 网络改进对于 $reward$ 的近似，是的后续计算更加准确。

(2) 优化目标：PPO 的优化目标基于三项损失的和，分别是策略损失、价值损失和熵正则项。

优化策略损失，使得策略朝着奖励增大的方向更新。具体来说，给定优势 $\hat{A}$ ，如果 $\hat{A} > 0$ ，则应该提高 $\pi_\theta(action|obs)$ ，如果 $\hat{A} < 0$ ，则应该降低 $\pi_\theta(action|obs)$ 。定义概率比：

$$ratio(\theta) = \frac{\pi_\theta(action|obs)}{\pi_{\theta_{old}}(action|obs)}$$

表示新策略相对旧策略在该 $(obs, action)$ 上的概率密度之比。 $ratio(\theta)$ 越大，新策略越倾向做该动作。使用概率比和 $\hat{A}$ 的乘积可以衡量策略损失：

$$L^{PG}(\theta) = \mathbb{E}_{(obs, action, reward) \sim \mathcal{D}}[ratio(\theta) \cdot \hat{A}(obs, action)]$$

其中 $\mathcal{D}$ 为多局单步游戏收集的 $(obs, action, reward)$ 组成的集合。设定损失函数为 $-L^{PG}(\theta)$ 。最小化损失函数，即最大化 $L^{PG}(\theta)$ ，让 θ 朝着奖励增大的方向更新。

为了防止更新幅度过大，定义经过裁剪策略损失：

$$L^{CLIP}(\theta) = \mathbb{E}_{(obs, action, reward) \sim \mathcal{D}}[\min(ratio(\theta) \cdot \hat{A}, \text{clip}(ratio(\theta), 1 - \epsilon, 1 + \epsilon) \cdot \hat{A})]$$

核心是使用 `clip` 函数裁剪 $ratio$ 。 ϵ 为裁剪半径，裁剪函数 $\text{clip}(ratio(\theta), 1 - \epsilon, 1 + \epsilon)$ 将概率比截断在 $[1 - \epsilon, 1 + \epsilon]$ ，以限制更新幅度。同理，使用 $-L^{CLIP}(\theta)$ 作为损失函数。

除了策略项更新，还需要更新 Critic 网络。定义价值损失：

$$L^{VF}(\phi) = \mathbb{E}_{(obs, action, reward) \sim \mathcal{D}}[(V_\phi(obs) - reward)^2].$$

价值损失越小，Critic 网络拟合的奖励越接近真实奖励，评价效果越好。

最后，提供一个熵正则项，用于提高策略的探索性：

$$\mathbb{E}_{(obs, action) \sim \mathcal{D}}[H(\pi\theta(\cdot|obs))]$$

熵越大，动作分布越均匀，探索越多。定义熵正则损失为 $-\mathbb{E}$ ，熵正则损失越小，探索性越高。

将三项损失线性相加，得到最终损失：

$$\mathcal{L}(\theta, \phi) = -L^{\text{CLIP}}(\theta) + c_1 \cdot \mathcal{L}^{\text{VF}}(\phi) - c_2 \cdot \mathbb{E}_{(s,a) \sim \mathcal{D}}[H(\pi\theta(\cdot|s))]$$

优化最终损失，可以使得策略朝着奖励增大的方向更新，同时保持策略的探索性。

4 其它格式

4.1 代码

4.1.1 原始代码

朴实的代码块：

使用 `verbatim` 可以得到原样的输出，如下：

```
print("Hello world!")
```

使用 `listings` 环境可以对代码进行进一步的格式化，如下：

```
import numpy as np  
  
a = np.zeros((2,2))  
print(a)
```

4.1.2 代码高亮

还可以对代码进行高亮，请参考 `Code Highlighting with minted`。请先到 `cls` 文件中启用 `minted` 库。注意使用 `Minted` 库时，需要系统默认 Python 有 `Pygments` 库，可以通过 `$ pip install Pygments` 来进行安装。且需要在编译时加上 `--shell-escape` 参数，否则会报错。

4.1.3 算法描述/伪代码

参考 `Algorithms`，下面是一个简单的示例：

算法 2: How to write algorithms

Result: Write here the result

```

1 initialization;
2 while While condition do
3   | instructions;
4   if condition then
5   | | instructions1;
6   else
7   | | instructions3;
8   end
9 end

```

4.2 绘图

关于使用 $\text{\LaTeX}$ 绘图的更多例子，请参考 `Pgfplots package` 中的例子。一般建议使用如 Photoshop、PowerPoint 等制图，再转换成 PDF 等格式插入。

4.3 写在最后

工具不重要，对工具的合理运用才重要。希望本模板对大家的论文写作有所帮助。

参考文献

- [1] HENNING T, OJHA S M, SPOON R, et al. Llm agents do not replicate human market traders: Evidence from experimental finance[A]. 2025. arXiv: 2502.15800.
- [2] JONES C M, SHI D, ZHANG X, et al. Retail trading and return predictability in china[J]. Journal of Financial and Quantitative Analysis, 2025, 60(1): 68-104.
- [3] 杨威, 冯璐, 宋敏, 等. 锚定比率可以衡量股价高估吗?—基于崩盘风险视角的经验证据[J]. 管理世界, 2020(1).
- [4] SHILLER R J. Do stock prices move too much to be justified by subsequent changes in dividends?[J]. American Economic Review, 1981, 71: 421-436.
- [5] 薛健, 汝毅. 信息披露业务关系与新闻报道质量[J]. 管理世界, 2020(10).
- [6] 伍戈, 陈得文. 为什么预期稳定是重要的——兼议货币市场上的规则与相机抉择政策[J]. 金融监管研究, 2015(5): 38-50.
- [7] 洪永淼, 汪寿阳. 大数据如何改变经济学研究范式?[J]. 管理世界, 2021(10).
- [8] SHARPE W F. Capital asset prices: A theory of market equilibrium under conditions of risk[J]. The Journal of Finance, 1964, 19(3): 425-442.
- [9] FAMA E F, FRENCH K R. The cross-section of expected stock returns[J]. The Journal of Finance, 1992, 47(2): 427-465.
- [10] GU S, KELLY B T, XIU D. Empirical asset pricing via machine learning[J]. The Review of Financial Studies, 2020, 33(5): 2223-2273.
- [11] 李斌, 邵新月, 李玥阳. 机器学习驱动的基本面量化投资研究[J]. 中国工业经济, 2019(8).
- [12] 马甜, 姜富伟, 唐国豪. 深度学习与中国股票市场因子投资——基于生成式对抗网络方法[J]. 经济学 (季刊), 2022(3).

- [13] MINSKY M. Steps toward artificial intelligence[J/OL]. Proceedings of the IRE, 1961. DOI: 10.1109/JRPROC.1961.287775.
- [14] TURGUT Y, BOZDAG C E. A framework proposal for machine learning-driven agent-based models through a case study analysis[J/OL]. Simulation Modelling Practice and Theory, 2023, 123: 102707. DOI: 10.1016/j.simpat.2022.102707.
- [15] AHMED S, ALSHATER M M, EL AMMARI A, et al. Artificial intelligence and machine learning in finance: A bibliometric review[J/OL]. Research in International Business and Finance, 2022, 61: 101646. DOI: 10.1016/j.ribaf.2022.101646.
- [16] LIU X Y, YANG H, GAO J, et al. Finrl: Deep reinforcement learning framework to automate trading in quantitative finance[A]. 2021.
- [17] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.

致谢

以简短的文字表达作者对完成论文和学业提供帮助的老师、同学、领导、同事及亲属的感激之情。

附录 A 因子说明

附录 B 系统设计

本研究涉及较长的数据周期，较多的 Agent 和数量庞大的因子数据，如果仅依赖单进程/本地数据，全量加载数据，需要极大的资源开销和运算时间。

为了解决训练问题，依照论文需要，设计了一个基于“数据流水线 + 分布式训练”的计算集群。

B.1 系统架构

B.2 数据流水线

B.3 分布式训练

