

武汉大学

本科毕业论文（设计）

国家网络安全学院毕业论文（设计）
模板预览及使用指南

姓 名：	XXX
学 号：	XXX
专 业：	XX 专业
学 院：	XX 学院
指导教师：	XXX 职称

二〇二五年 X 月

原创性声明

本人郑重声明：所呈交的论文（设计），是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文（设计）不包含任何其他个人或集体已发表及撰写的研究成果。对本论文（设计）做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文（设计）工作过程中没有伪造数据等行为。若在本论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：

指导教师签名：

日 期：

年 月 日

版权使用授权书

本人完全了解武汉大学有权保留并向有关部门或机构送交本论文（设计）的复印件和电子版，允许本论文（设计）被查阅和借阅。本人授权武汉大学将本论文的全部或部分内容编入有关数据进行检索和传播，可以采用影印、缩印或扫描等复制手段保存和汇编本论文（设计）。

作者签名：

指导教师签名：

日 期：

年 月 日

摘 要

请使用中文分号“;”分割关键词!

摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容
摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要
内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容
摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要内容摘要
内容

关键词: 关键词 1; 关键词 2; 关键词 3

ABSTRACT

Please use English semicolon and space to separate key words.

This is abstract. This is abstract. This is abstract. This is abstract. This is abstract.
This is abstract. This is abstract. This is abstract. This is abstract. This is abstract. This
is abstract. This is abstract. This is abstract. This is abstract. This is abstract. This is
abstract. This is abstract. This is abstract. This is abstract.

Keywords: Key1; Key2; Key3

目 录

摘 要	I
ABSTRACT	II
1 引言	1
2 文献综述	3
2.1 预期共识度量	3
2.2 基于 Agent 的实验金融研究	5
2.3 文献评价	6
3 研究设计	7
3.1 Agent 投资者设计	7
3.1.1 数据输入	7
3.1.2 神经网络	9
3.1.3 奖励函数	11
3.1.4 强化学习	12
3.1.5 滚动窗口	14
3.1.6 参数设置	14
3.2 指标设计	14
4 实证分析	16
5 进一步研究	17
6 结论与建议	18
参考文献	19

致谢	24
附录 A 因子说明	25
附录 B 系统设计	26
B.1 系统架构	26
B.1.1 总体架构设计	26
B.1.2 中央控制节点	27
B.1.3 系统组件	27
B.1.4 系统工作流程	28
B.2 数据流水线	29
B.2.1 消息流	29
B.3 分布式训练	31

1 引言

金融市场是一个具有动态演化特征的复杂协调系统，金融产品价格在很大程度上受到投资者预期的影响。而大量投资者形成的共同预期对资产定价的系统性影响，即“预期共识效应”，是理解市场定价逻辑的重要命题^[1]。长期以来，中国股票市场以散户投资者为主导，贡献了超 80% 的市场交易量^[2]。与机构投资者相比，散户的信息获取与处理能力有限，难以精准解读复杂的公司基本面与市场信号，其决策更易受情绪、短期市场趋势等因素影响^[3]，最终表现为对个股的预期方向呈现显著的集体性乐观或悲观的“共识”^[4]。这种散户主导的“预期共识”现象，是否会成为 A 股资产定价的驱动因素，这一问题尚未得到充分的系统性解答，而其答案直接关联到金融预期政策的实施精度：无论是学术研究^[5]，还是党的会议部署，均强调了引导市场理性预期、维护资本市场稳定的重要性。因此，系统探究 A 股市场中投资者预期共识的定价效应，明确其作用机制、定价效力与适用边界，对于精准实施预期管理、促进资本市场平稳运行，具有重要的理论价值与现实意义。

近年来，机器学习方法在经济、金融、管理等领域受到的重视程度日益提高^[6]。在资产定价领域，因子分析法^{[7][8]}自诞生以来，被广泛应用于资产定价研究。而机器学习方式，以其数据驱动的特性和强大的非线性拟合能力，逐渐成为资产定价研究的热点。Gu, Kelly, Xiu 等学者^[9]通过对比包括随机森林、梯度提升树、感知机在内的 14 种机器学习方法，发现机器学习在挖掘高维公司特征的非线性关系方面具有显著优势，解释力远强于传统因子模型。在国内，李斌等学者^[10]基于 A 股因子，对比了神经网络、支持向量机等模型在 A 股收益预测中的表现，发现机器学习能够有效捕捉 A 股“壳价值”“政策敏感性特征”等特殊定价因素。马甜等学者^[11]将生成式对抗网络引入 A 股因子构建，缓解了因子的稀疏性问题，构建的深度学习复合因子 A 股市场的表现优于传统因子。因子是对公司信息的提取和抽象，而机器学习通过对于因子的非线性拟合，可以模拟投资者对于公司信息的非线性处理过程，从而更准确地预测资产价格。

人工智能技术的发展为金融研究提供了新的视角和工具。Minsky 在 1961 年首次提出了“Agent”的概念^[12]，将 Agent 定义为能够通过协商协作解决问题的

智能个体”，强调其社会交互性、自主性两大核心特性。相比于传统机器学习用于预测、分类等任务，Agent 可以直接模拟投资者“端到端”的决策过程，即收集信息、解读信息、决策、执行、反馈的完整过程^[13]。自 2015 年来，Agent-Based 金融研究数量迅速增加，覆盖了股票价格预测、投资组合管理、风险管理等多个领域^[14]。使用 AI-Agent 模拟投资者决策过程，可以更准确地模拟投资者的决策过程，对于投资者预期协同度的研究具有重要的理论价值与现实意义。

强化学习（Reinforcement Learning, RL）是人工智能领域在序列决策任务中的重要研究方向。在强化学习框架中，Agent 通过与环境交互，学习最优策略，以最大化长期累积奖励，与投资者在金融市场中的决策-学习-反馈-再决策的过程具有一致性。因此，强化学习被广泛应用于金融市场的研究中。在投资组合管理（Portfolio Management, PM）领域，RL 可以灵活设计奖励，纳入交易成本、风险约束、长期收益等目标，解决跨期资产配置问题^[15]；在多 Agent 协同决策（Multi-Agent Reinforcement Learning, MARL）领域，RL 可以模拟多个 Agent 之间的交互，学习最优策略，提供更丰富的资产配置策略^[16]。使用 RL 模拟投资者决策过程，与现实的交易情景更加贴近，将 Agent 投资者置于更真实的场景。

2 文献综述

2.1 预期共识度量

本文所指的预期共识，是投资者对个股未来收益的“整体预期方向与平均水平”。因此，如何度量单个投资者的预期水平，是研究预期共识效应的关键。然而，在传统的金融实证研究中，度量单个投资者的预期较为困难，方法主要集中于调研的宏观预期指标、代理指标、分析师预期分歧和文本分析^[17]，间接衡量投资者的预期水平。然而，这些方法均存在局限性。

宏观预期指标通过调研消费者信心或经济预期反映市场整体情绪，典型代表如密歇根大学消费者信心指数、MM 经济预期指数。Lemmon 等学者曾使用这类指数作为投资者乐观程度的代理变量^[18]，分析其对小市值股票溢价的影响。但此类指标聚焦宏观经济层面，反映的是全市场整体情绪趋势，无法精准捕捉个股层面的预期共识；

市场代理指标通过金融市场交易数据间接映射投资者预期共识。朱宏泉等学者^[19]使用未预期到的换手率作为代理变量，剔除习惯性交易、流动性需求等无关因素后，间接反映投资者对个股的预期共识变动；孟庆斌等学者^[20]则以卖空量作为悲观预期共识的代理指标，认为卖空行为的聚合体现了市场对个股的集体看空倾向。但这类指标存在明显局限。未预期换手率仅能反映共识的“变动趋势”，无法直接量化共识的具体方向与强度。卖空量仅能覆盖悲观共识，难以全面捕捉乐观共识，存在维度片面性。并且，上述方法也均无法直接刻画散户群体的真实预期倾向。

分析师预期聚合通过汇总专业分析师的预测结果近似反映预期共识。Diether 等学者曾基于分析师盈余预测的均值构建预期水平指标^[21]，Anderson 等学者则通过分析师长期盈余增长预测的平均水平衡量共识强度^[22]。但分析师群体的局限性显著：一是样本覆盖不足，难以覆盖全时期、全证券的预期共识，尤其对中小盘个股的覆盖缺口较大；二是代表性偏差，分析师多服务于机构投资者，其预期难以替代散户主导市场的集体共识；三是预测失真风险，分析师预测易受自身利益冲突、行业压力等因素影响^[23]，导致共识度量的真实性受损。

文本情绪分析法通过挖掘非结构化文本数据中的情绪倾向，聚合形成预期

共识。部慧等学者利用股评文本构建投资者情绪指数^[2]，万海远等学者通过企业调研文本与政策文本分析企业预期变动^[2]，均试图通过文本聚合捕捉市场共识。但此类方法面临多重挑战，如数据存在大量噪声，刻意披露行为，信息密度低等问题。

随着机器学习和人工智能技术的发展，Agent 的使用为刻画投资者预期提供了全新的视角。Hornik 等学者在其经典研究中证明了多层感知机 (MLP) 可以逼近任意连续函数^[23]。因此，基于神经网络的 Agent 可以模拟投资者在真实市场中对于信息的处理和决策过程，从而较好地刻画单个投资者预期。投资者的信念受其获取的信息^[24]，和对于信息解读^[25]^[26]的过程影响。对于 Agent，其输入和解读的方式都可以通过调整神经网络参数的方式进行模拟，从而更贴合真实投资者的行为。唐国豪等学者^[17]通过多个神经网络，构建了投资者预期协同度量模型，使用不同初始化参数的多层感知机模拟单个投资者的预期。因此，使用 Agent 模拟单个投资者，在理论和实践上均有可行性，为解决预期共识度量问题提供了新的思路。

Miller 在 1977 年提出的经典假说：在存在卖空约束的市场中，悲观投资者无法通过卖空交易充分表达其负面预期，资产价格将主要由乐观投资者的信念决定；投资者预期分歧越大，预期共识越低，股价被乐观预期高估的程度就越严重，对应的股票未来收益也越低^[27]。这一假设成为投资者预期在资本市场定价中的重要基石。在实证研究中，Diether 等学者使用分析师预期分歧^[21]，Johnson 使用期权定价理论^[28]，Yu 从资产组合视角出发，均验证了预期共识越低，股票未来收益越低的结论。而 Greenwood 和 Shleifer 使用美国投资者的预期调研数据，直接度量了投资者的预期共识，发现预期共识度越高，股票未来收益越高^[1]。国内，唐国豪等学者使用大量神经网络模型，模拟异质性个体投资者的预期，验证了预期共识越低，股票未来收益越低的结论^[17]。

关于预期共识定价的机制，一种主要的解释是套利限制引发的错误定价。根据 Miller 的假说^[27]，在具有卖空约束的市场中，悲观的投资者无法通过做空实现自己的收益，无法具体表达自己的预期，因此，股价被乐观投资者的信念决定。

2.2 基于 Agent 的实验金融研究

随着 AI 技术的发展，Agent 已经被广泛应用于实验金融领域^[14]。

Agent 因其输入、计算、反馈的灵活性，已经被广泛用于实验金融，模拟个体投资者的决策过程。Henning 等学者^[29]使用 Agent 模拟大量投资者在市场上的交易行为，发现 Agent 的决策过程相比于人类有着“教科书式理性”，不会出现市场泡沫等非理性行为。AI-Hedge Fund 项目拓展了多智能体协作的投资决策场景，通过构建包含价值投资、成长投资、逆向投资等多元风格的专家智能体与功能分析模块，实现了从信息整合、风险评估到组合决策的全流程投资模拟，为探究专业化投资群体的预期聚合机制提供了可复用的技术框架^[30]。TwinMarket 系统在 A 股市场环境中，使用多 Agent 系统模拟散户的预期互动、情绪传染等现象，探究行为金融与价格形成的关系^[31]。

强化学习作为一种机器学习范式，通过智能体与环境的交互学习最优策略，已在金融交易领域展现出巨大潜力。与传统监督学习相比，RL 能够灵活地考虑交易成本、风险控制等因素，并直接生成动态的资产权重分配策略^{[32] [33]}。

在投资组合管理（Portfolio Management）领域，RL 通过多资产权重再分配问题建模，能够克服传统方法的局限性。Shi 等人^[15]提出的 XPM 框架结合了解释性深度强化学习，针对投资组合选择问题构建了可解释的决策模型。该研究通过注意力机制捕捉资产间的相关性，并在多个基准数据集上验证了模型的有效性，证明了 RL 在处理高维金融时序数据时的优势。

Marzban 等人^[34]则关注资产相关性的建模问题，提出了 WaveCorr 框架。该方法巧妙地将相关性信息融入 RL 的决策过程，通过小波变换提取多尺度相关性特征，在波动性强的市场环境下取得了优于传统方法的表现。

Liu 等人^[35]开发的 FinRL 框架，成为金融强化学习研究的重要工具。该框架定义了滚动窗口训练方式，输入为一个维度为 $(n, m, l + 1)$ 的三维张量，其中 n 为证券数量，表示证券组合中的证券数量； m 为时间窗口长度，表示 Agent 可以回顾过去 m 个月的数据； l 为因子数量，可以由用户自定义因子计算模式，并附带一个现金项。随后，将该三维张量进行展平，使用 MLP 模型作为 Agent 决策模型，输出为 $n + 1$ 维向量，对应 n 只证券的权重及一个现金项。该框架支持多种强化学习算法，包括 PPO, DNQ 等，并提供了丰富的奖励函数和评估指标，包括

收益率，夏普比率等。

2.3 文献评价

3 研究设计

3.1 Agent 投资者设计

对于一个 Agent 投资者，其决策和学习的过程可以分为以下几个步骤：

算法 1: Agent 投资者决策过程

Input: 特征数据

Result: 更新后的神经网络

- 1 特征数据 $\xrightarrow{\text{神经网络}}$ 投资决策 @;
 - 2 投资决策、收益数据 $\rightarrow$ 组合收益;
 - 3 组合收益序列 $\rightarrow$ 组合表现指标（如波动率、夏普比率、最大回撤等）;
 - 4 组合表现指标 $\rightarrow$ 奖励;
 - 5 奖励 $\rightarrow$ 更新后的神经网络;
 - 6 重复上述步骤，直到达到预设的训练次数或达到预设的训练时间。
-

@同一过程可旁支用于计算 AED

根据上述步骤，可以设计一个 Agent 投资者的决策和学习过程。

3.1.1 数据输入

使用因子数据作为 Agent 投资者的输入，用于模拟投资者对于因子的解读和决策。因子数据是以年月-证券为主键的月度面板数据。记原始的因子数据为 $raw_factors_{a,s,t,i}$ ，表示第 a 个 Agent 在 t 月份对于证券 s 的因子 i 的原始值。

由于不同特征的量纲、数量级、分布等方面存在明显差异，因此需要对特征进行标准化处理，使得所有特征的均值为 0，标准差为 1。具体来说，记 N 为参与该月标准化的证券数量（如股票池大小）。对于每一个因子 $factor_{a,s,t,i}$ ，求相同月份所有证券的因子值的均值和标准差：

$$raw_mu_{t,i} = \frac{1}{N} \sum_{s=1}^N raw_factors_{a,s,t,i}$$

$$raw_sigma_{t,i} = \sqrt{\frac{1}{N} \sum_{s=1}^N (raw_factors_{a,s,t,i} - raw_mu_{t,i})^2}$$

然后对每一个因子进行标准化处理，得到标准化后的因子值：

$$factor_{a,s,t,i} = \frac{raw_factors_{a,s,t,i} - raw_μ_{t,i}}{raw_σ_{t,i}}$$

参考 FinRL^[35] 的设计，设定一个因子向量为：

$$\vec{factors}_{a,s,t} = (factor_{a,s,t,1}, factor_{a,s,t,2}, \dots, factor_{a,s,t,i}, \dots)^T$$

考虑到不同的 Agent 投资者的数据获取能力不同，对数据的关注程度也不同，可以使用“随机选择”的方法定义不同的投资者^[36]，类似于机器学习中的特征选择方法^[37]。设定 Agent_a 只能随机获取 88 个因子中的 l 个因子，用于分析决策。筛选后的因子向量为：

$$selected_factors_{a,s,t} = (factor_{a,s,t,random_1}, factor_{a,s,t,random_2}, \dots, factor_{a,s,t,random_i}, \dots)^T$$

其中 $random_i$ 为随机选择的因子索引，不同的 Agent 投资者选择的因子索引不同。

设定 Agent 拥有一定的数据回顾能力，可以回顾过去 m 个月的因子向量。在月份 t ，Agent 可以回顾过去 m 个月的因子向量，形成一个 (m, l) 的矩阵，记作：

$$factors_matrix_{a,s,t} = (factors_{a,s,t}, factors_{a,s,t-1}, \dots, factors_{a,s,t-m+1})$$

Agent 需要选择 n 只证券，构建一个投资组合，记作：

$$portfolio = (s_1, s_2, \dots, s_n)$$

将多个证券的因子矩阵拼接，可以得到一个三维张量，记作：

$$factors_tensor_{a,portfolio,t} = \begin{pmatrix} factors_matrix_{a,s_1,t} \\ factors_matrix_{a,s_2,t} \\ \vdots \\ factors_matrix_{a,s_n,t} \end{pmatrix}$$

其维度为 (n, m, l) 。

最后，Agent 可以回顾自己之前投资组合的收益情况，对于投资组合 $portfolio$ ，获取其 $t, t-1, t-2, \dots, t-m+1$ 月的收益，组成收益序列，记作：

$$returns_{a,portfolio,t} = (return_{a,portfolio,t-m+1}, return_{a,portfolio,t-m+2}, \dots, return_{a,portfolio,t})$$

其中， $return_{a,portfolio,t}$ 为使用 $t-1$ 月的决策构建投资组合 $portfolio$ 在 t 月份的收益。其计算方式为各个证券在 $t-1$ 月的决策水平其在 t 月份的收益水平

的加权平均值。记 $w_{a,portfolio,t,s}$ 为第 a 个 Agent 在 t 月份对于证券 s 的决策权重， $return_{s,t}$ 为证券 s 在 t 月份的收益，则：

$$return_{a,portfolio,t} = \sum_{s=1}^{n+1} w_{a,portfolio,t-1,s} \cdot return_{s,t}$$

其中， $w_{a,portfolio,t,n+1}$ 为现金权重，表示分配给无风险资产（现金）的比例，对应 $return_{n+1,t}$ 为无风险收益率。

该收益序列与具体证券无关，为组合整体收益。为与按证券组织的输入一致，将该收益序列复制 n 份，得到形状为 (n, m) 的矩阵（每行均为同一 m 维收益序列），记作：

$$\mathbf{returns_matrix}_{a,portfolio,t} = \begin{pmatrix} return_{a,portfolio,t-m+1} & return_{a,portfolio,t-m+2} & \dots & return_{a,portfolio,t} \\ return_{a,portfolio,t-m+1} & return_{a,portfolio,t-m+2} & \dots & return_{a,portfolio,t} \\ \vdots & \vdots & \vdots & \vdots \\ return_{a,portfolio,t-m+1} & return_{a,portfolio,t-m+2} & \dots & return_{a,portfolio,t} \end{pmatrix}$$

再将该矩阵在特征维上扩展为形状为 $(n, m, 1)$ 的三维张量，并与原有 (n, m, l) 张量在特征维上拼接，得到最终输入张量，其维度为 $(n, m, l+1)$ ，记作：

$$\mathbf{X}_{a,portfolio,t} = \begin{pmatrix} \mathbf{factors_matrix}_{a,s_1,t} \\ \mathbf{factors_matrix}_{a,s_2,t} \\ \vdots \\ \mathbf{factors_matrix}_{a,s_n,t} \\ \mathbf{returns_matrix}_{a,portfolio,t} \end{pmatrix}$$

3.1.2 神经网络

与预测模型不同，Agent 的神经网络采用端到端设计，无需预测组合未来的收益，而是直接进行决策，决定将多少比例的资金分配给每只证券（现金）。

（1）数据输入层：参考 FinRL^[35]，采用多层感知机（MLP）作为 Agent 由观测到投资权重的映射模型。输入为前述的观测张量 $\mathbf{X}_{a,portfolio,t}$ ，形状为 $(n, m, l+1)$ 。

（2）展平与线性层：将输入张量展平为一维向量，记作：

$$\mathbf{x} = \text{Flatten}(\mathbf{X}_{a,portfolio,t}) \quad \mathbf{x} \in \mathbb{R}^{nm(l+1)}$$

经过 Dropout 层后，得到：

$$\mathbf{x}' = \text{Dropout}(\mathbf{x}) \quad \mathbf{x}' \in \mathbb{R}^{nm(l+1)}$$

然后通过一层全连接层映射为 $n+1$ 维向量，记作：

$$\mathbf{z} = \mathbf{W}\mathbf{x}' + \mathbf{b} \quad \mathbf{W} \in \mathbb{R}^{(n+1) \times nm(l+1)}, \mathbf{b} \in \mathbb{R}^{n+1},$$

得到 $\mathbf{z} \in \mathbb{R}^{n+1}$ ，对应 n 只证券的权重及一个现金（无风险资产）维度。

(3) **激活函数**：使用 Tanh 函数作为激活函数，将输出映射到 $(-1, 1)$ 之间。

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

经过 Tanh 函数激活后，得到模型输出，记作：

$$\mathbf{o}_{a, portfolio, t} = \tanh(\mathbf{z}) \quad \mathbf{o}_{a, portfolio, t} \in \mathbb{R}^{n+1}$$

使用 Tanh 作为激活函数，可以保留负权重，用于后续研究中放松对于杠杆和做空的限制。

(4) **输出归一化**：按照决策的语义，Agent 的决策（行动）可以表示为一个和为 1 的向量，记作：

$$\vec{action}_{a, portfolio, t} = (w_1, w_2, \dots, w_{n+1}) \in \mathbb{R}^{n+1}$$

其中， w_i 表示分配给证券（现金） i 的比例。设定最后一个权重 w_{n+1} 为现金权重，表示分配给无风险资产（现金）的比例。

在基线回归中，设定不允许使用杠杆或者做空。因此，将 $\mathbf{o}_{a, portfolio, t}$ 转换为决策向量 $\vec{action}_{a, portfolio, t}$ ，需要满足以下约束：

1) 权重之和为 1，即 $\sum_{i=1}^{n+1} w_i = 1$ ，表示需要将全部资金用完，无用的资金需要分配给无风险资产（现金）；

2) 非负，即 $w_i \geq 0$ ，表示不允许做空证券，或者使用杠杆（即现金权重为负，表示借入资金购买证券）；

将 $\mathbf{o}_{a, portfolio, t}$ 记作：

$$\mathbf{o}_{a, portfolio, t} = (o_1, o_2, \dots, o_{n+1})$$

为了满足非负性约束，将 $\mathbf{o}_{a, portfolio, t}$ 中的负权重部分截断为 0，得到：

$$o_i^+ = \max(o_i, 0)$$

$$\mathbf{o}_{a, portfolio, t}^+ = (o_1^+, o_2^+, \dots, o_{n+1}^+)$$

然后进行简单归一化，得到归一化后的决策向量，记作：

$$\vec{action}_{a,portfolio,t} = \left(\frac{o_1^+}{\sum_{i=1}^{n+1} o_i^+}, \dots, \frac{o_{n+1}^+}{\sum_{i=1}^{n+1} o_i^+} \right)$$

3.1.3 奖励函数

在强化学习中，奖励函数是 Agent 用于评估其决策好坏，改进决策方向，实现模型优化的关键。参考 Moody 等^[38]和 jiang 等^[39]的研究，使用二次效用函数^[40]作为奖励函数。

$$u = \mu - \frac{A}{2}\sigma^2$$

具体来说,对于一个投资组合 $portfolio$,其在 t 月份的收益率为 $return_{a,portfolio,t}$ 。由于可能涉及采样算法，计算奖励前，需要再对 $\vec{action}_{a,portfolio,t}$ 进行归一化。后续计算方式和前述相同。

Agent 在 t 时间点上决策，获取 $\vec{action}_{a,portfolio,t}$ ，计算持有该组合到下一个时间点期间的收益 $return_{a,portfolio,t+1}$ ，作为期望收益 μ 。

再获取其前 m 个月的收益序列：

$$\vec{returns}_{portfolio,t} = (return_{portfolio,t}, return_{portfolio,t-1}, \dots, return_{portfolio,t-m+1})$$

计算历史收益的样本均值：

$$\bar{r}_{portfolio,t} = \frac{1}{m} \sum_{i=0}^{m-1} return_{portfolio,t-i}$$

然后计算历史收益的方差：

$$\sigma^2 = \frac{1}{m} \sum_{i=0}^{m-1} (return_{portfolio,t-i} - \bar{r}_{portfolio,t})^2$$

参数 A 是风险厌恶系数。 A 越大，表明 Agent 越厌恶风险，越倾向于选择低风险的组合。根据尹海员等^[41]、张玥^[42]、jiang^[43]等学者的研究，在 A 股市场中，投资者的风险系数的取值范围在 $[2, 8]$ 之间，具有厚尾、右偏的分布特征。因此，使用对数正态分布采样 Agent 的风险厌恶系数。

$$\ln(A) \sim N(\mu_A, \sigma_A^2)$$

该分布具有恒正、右偏、厚尾的特征，符合投资者风险厌恶系数的分布特征。

3.1.4 强化学习

3.1.4.1 游戏设定

在本研究中，将投资组合决策建模为单步强化学习环境，每一次决策构成一局完整的游戏。在该设定下，Agent 在观测到因子数据后 obs 后，根据当前策略做出决策 $action$ ，并返回奖励 $reward$ 。 $reward$ 由二次效用函数计算得到，记作 $reward = (obs, action)$ 记每局对应一个转移 $(obs, action, reward)$ 。

强化学习的目标为，得到一个策略 π ，使得在观察到因子数据 obs 后，根据策略 π 做出的决策 $action$ ，能够最大化奖励 $reward$ 。

记策略 $\pi = \pi(action|obs)$ ，表示在 obs 观测下，做出决策 $action$ 的概率。则学习目标为：

$$J(\pi) = \mathbb{E}_{obs, action \sim \pi}[reward(obs, action)]$$

定义神经网络的参数为 θ ，则策略 π 可以表示为：

$$\pi_{\theta}(action|obs)$$

优化目标为：

$$J(\theta) = \mathbb{E}_{obs, action \sim \pi}[reward(obs, action)]$$

3.1.4.2 PPO 算法

使用近端策略优化（Proximal Policy Optimization, PPO）算法作为强化学习算法。PPO 策略由 Schulman 等^[44]提出，是一种基于策略梯度算法的强化学习算法。通过计算新的策略与当前策略的优势更新策略，并且通过限制概率比和裁剪的方式，避免策略更新幅度过大。该算法具有较好的收敛性和稳定性，适用于连续动作空间的问题。

使用 Stable-Baselines3(SB3)^[45]框架实现 PPO 算法。

(1) Actor-Critic 网络： PPO 使用 Actor-Critic 网络优化策略。Actor 网络用于生成策略，使用前述的神经网络 f 作为 Actor 网络。Actor 网络将 $f_{\theta}(obs)$ 映射为均值为 $f_{\theta}(obs)$ ，方差为 σ^2 的正态分布，在以这个分布作为策略 $\pi_{\theta}(action|obs)$ ，探索动作空间，记为：

$$\pi_{\theta}(action|obs) \sim \mathcal{N}(f_{\theta}(obs), \sigma^2)$$

价值函数 $V_\phi(obs)$ 用于评估当前策略的优劣势，其中， ϕ 为 Critic 网络的参数。用于拟合状态价值函数：

$$V^\pi(obs) = \mathbb{E}_{action \sim \pi(\cdot|obs)}[reward(obs, action)]$$

Critic 学习对上述期望的近似，即 $V_\phi(obs) \approx V^\pi(obs)$ ，作为基线，评估实际奖励 $reward$ 与期望奖励 $V^\pi(obs)$ 的差距：

$$\hat{A}(obs, action) = reward(obs, action) - V_\phi(obs)$$

通过不断训练，Critic 网络改进对于 $reward$ 的近似，是的后续计算更加准确。

(2) 优化目标：PPO 的优化目标基于三项损失的和，分别是策略损失、价值损失和熵正则项。

优化策略损失，使得策略朝着奖励增大的方向更新。具体来说，给定优势 $\hat{A}$ ，如果 $\hat{A} > 0$ ，则应该提高 $\pi_\theta(action|obs)$ ，如果 $\hat{A} < 0$ ，则应该降低 $\pi_\theta(action|obs)$ 。定义概率比：

$$ratio(\theta) = \frac{\pi_\theta(action|obs)}{\pi_{\theta_{old}}(action|obs)}$$

表示新策略相对旧策略在该 $(obs, action)$ 上的概率密度之比。 $ratio(\theta)$ 越大，新策略越倾向做该动作。使用概率比和 $\hat{A}$ 的乘积可以衡量策略损失：

$$L^{PG}(\theta) = \mathbb{E}_{(obs, action, reward) \sim \mathcal{D}}[ratio(\theta) \cdot \hat{A}(obs, action)]$$

其中 $\mathcal{D}$ 为多局单步游戏收集的 $(obs, action, reward)$ 组成的集合。设定损失函数为 $-L^{PG}(\theta)$ 。最小化损失函数，即最大化 $L^{PG}(\theta)$ ，让 θ 朝着奖励增大的方向更新。

为了防止更新幅度过大，定义经过裁剪策略损失：

$$L^{CLIP}(\theta) = \mathbb{E}_{(obs, action, reward) \sim \mathcal{D}}[\min(ratio(\theta) \cdot \hat{A}, 1 - \epsilon, 1 + \epsilon)]$$

核心是使用 `clip` 函数裁剪 $ratio$ 。 ϵ 为裁剪半径，裁剪函数 $clip(r(\theta), 1 - \epsilon, 1 + \epsilon)$ 将概率比截断在 $[1 - \epsilon, 1 + \epsilon]$ ，以限制更新幅度。同理，使用 $-L^{CLIP}(\theta)$ 作为损失函数。

除了策略项更新，还需要更新 Critic 网络。定义价值损失：

$$L^{VF}(\phi) = \mathbb{E}_{(obs, action, reward) \sim \mathcal{D}}[(V_\phi(obs) - reward)^2].$$

价值损失越小，Critic 网络拟合的奖励越接近真实奖励，评价效果越好。

最后，提供一个熵正则项，用于提高策略的探索性：

$$L^H(\theta) = \mathbb{E}_{(obs, action) \sim \mathcal{D}}[H(\pi\theta(\cdot|obs))]$$

熵越大，动作分布越均匀，探索越多。定义熵正则损失为 $-L^H(\theta)$ ，熵正则损失越小，探索性越高。

将三项损失线性相加，得到最终损失：

$$\mathcal{L}(\theta, \phi) = -L^{CLIP}(\theta) + c_1 \cdot \mathcal{L}^{VF}(\phi) - c_2 \cdot L^H(\theta)$$

优化最终损失 $\mathcal{L}(\theta, \phi)$ ，可以使得策略朝着奖励增大的方向更新，同时保持策略的探索性。

3.1.5 滚动窗口

参考唐国豪^[17]，FinRL^[35]等做法，使用滚动窗口的方式训练 Agent，同时收集数据，用于后续因子构建。

由于计算奖励需要单个证券组合的历史收益序列，需要确保证券组合在窗口中保持不变。因此，进行提前采样，对于证券池 $\mathcal{S}$ ，一共有 S 只证券，若一个证券组合由 n 只证券组成，则最多可构建 $\binom{S}{n}$ 个不同的证券组合。选取其中 N 个证券组合 $\mathcal{P} = \{\vec{portfolio}_1, \vec{portfolio}_2, \dots, \vec{portfolio}_N\}$ 。

对于一个时间窗口 t ，遍历所有证券组合 $\vec{portfolio} \in \mathcal{P}$ ，每次输入观测 $\mathbf{X}_{a, \vec{portfolio}, t}$ ，得到决策 $action_{a, \vec{portfolio}, t}$ ，计算奖励 $reward(obs, action)$ ，更新网络参数。遍历完成后，进入下一个时间窗口 $t+1$ ，然后打乱 $\mathcal{P}$ ，重复上述过程。

3.1.6 参数设置

3.2 指标设计

为了刻画 Agent 投资者的预期协同效应，参考唐国豪等^[17]、Bali 等^[36]、Hong 等^[46]、Banerjee 等^[47]的做法，构建 $AED_{s,t}$ 指标，即 Agent 预期分散度 (Agent Expectation Dispersion, AED)，用于刻画 Agent 投资者的预期协同效应。

具体来说，第 a 个 Agent 对于证券 s 的投资决策为 $action_{a,s,t}$ ，记 $MA_{s,t}$ 为 t 月份证券 s 的平均投资决策：

$$MA_{s,t} = \frac{1}{N} \sum_{a=1}^N action_{a,s,t}$$

$SA_{s,t}$ 为 t 月份证券 s 决策标准差：

$$SA_{s,t} = \sqrt{\frac{1}{N} \sum_{a=1}^N (action_{a,s,t} - MA_{s,t})^2}$$

则：

$$AED_{s,t} = \frac{MA_{s,t}}{SA_{s,t}}$$

AED 用于综合刻画投资这对证券决策的强度和集中度。如果大部分投资者都倾向于一致做多证券 s ，则 MA 较大， SA 较小， AED 较大，表示投资者一致看好证券 s 。如果大部分投资者都倾向于一致做空证券 s ，则 MA 较小， SA 较小， AED 较小，表示投资者一致看空证券 s 。如果投资者对于证券 s 的决策较为分散，则 SA 较大， AED 较小，表示投资者无法形成一致预期。

4 实证分析

实证结果如表 ?? 所示。

表 4.1 分组检验与对冲组合收益表现（含 p 值）

分组 ID	平均收益率	夏普比率	CAPM Alpha	FF3 Alpha	FF5 Alpha
组合 1	-0.060	-4.664	-0.191**	-0.173**	-0.146*
	[-0.660]		[-2.216]	[-2.059]	[-1.742]
	(0.510)		(0.028)	(0.040)	(0.082)
组合 2	0.036	3.149	-0.104	-0.091	-0.062
	[0.413]		[-1.364]	[-1.253]	[-0.879]
	(0.680)		(0.174)	(0.211)	(0.380)
组合 3	0.117	11.580	-0.019	-0.003	0.016
	[1.518]		[-0.279]	[-0.039]	[0.251]
	(0.130)		(0.780)	(0.969)	(0.802)
组合 4	0.163***	21.000	0.025	0.038	0.059
	[2.655]		[0.484]	[0.774]	[1.246]
	(0.008)		(0.629)	(0.439)	(0.213)
组合 5	0.202***	33.130	0.068*	0.081**	0.101***
	[4.400]		[1.698]	[2.124]	[2.653]
	(0.000)		(0.091)	(0.035)	(0.008)
对冲组合	0.263***	27.180	0.134*	0.129*	0.122*
	[3.643]		[1.880]	[1.840]	[1.746]
	(0.000)		(0.061)	(0.066)	(0.082)

注：1. 所有值均已百分化；

2. 所有 t 值计算使用 Newy-West 标准误；

3. * $p < 0.1$, ** $p < 0.05$, *** $p < 0.01$ 。

5 进一步研究

6 结论与建议

参考文献

- [1] GREENWOOD R, SHLEIFER A. Expectations of returns and expected returns [J]. The Review of Financial Studies, 2014, 27(3): 714-746.
- [2] JONES C M, SHI D, ZHANG X, et al. Retail trading and return predictability in china[J]. Journal of Financial and Quantitative Analysis, 2025, 60(1): 68-104.
- [3] 薛健, 汝毅. 信息披露业务关系与新闻报道质量[J]. 管理世界, 2020(10).
- [4] KUMAR A, LEE C M C. Retail investor sentiment and return comovements [J/OL]. The Journal of Finance, 2006, 61(5): 2451-2486. DOI: 10.1111/j.1540-6261.2006.01063.x.
- [5] 伍戈, 陈得文. 为什么预期稳定是重要的——兼议货币市场上的规则与相机抉择政策[J]. 金融监管研究, 2015(5): 38-50.
- [6] 洪永淼, 汪寿阳. 大数据如何改变经济学研究范式?[J]. 管理世界, 2021(10).
- [7] SHARPE W F. Capital asset prices: a theory of market equilibrium under conditions of risk[J]. The Journal of Finance, 1964, 19(3): 425-442.
- [8] FAMA E F, FRENCH K R. The cross-section of expected stock returns[J]. The Journal of Finance, 1992, 47(2): 427-465.
- [9] GU S, KELLY B T, XIU D. Empirical asset pricing via machine learning[J]. The Review of Financial Studies, 2020, 33(5): 2223-2273.
- [10] 李斌, 邵新月, 李玥阳. 机器学习驱动的基本面量化投资研究[J]. 中国工业经济, 2019(8).
- [11] 马甜, 姜富伟, 唐国豪. 深度学习与中国股票市场因子投资——基于生成式对抗网络方法[J]. 经济学 (季刊), 2022(3).
- [12] MINSKY M. Steps toward artificial intelligence[J/OL]. Proceedings of the IRE, 1961. DOI: 10.1109/JRPROC.1961.287775.

- [13] TURGUT Y, BOZDAG C E. A framework proposal for machine learning-driven agent-based models through a case study analysis[J/OL]. *Simulation Modelling Practice and Theory*, 2023, 123: 102707. DOI: 10.1016/j.simpat.2022.102707.
- [14] AHMED S, ALSHATER M M, EL AMMARI A, et al. Artificial intelligence and machine learning in finance: a bibliometric review[J/OL]. *Research in International Business and Finance*, 2022, 61: 101646. DOI: 10.1016/j.ribaf.2022.101646.
- [15] SHI S, LIU Y, ZHANG C, et al. XPM: an explainable deep reinforcement learning framework for portfolio management[C/OL]//*Proceedings of the 30th ACM International Conference on Big Data Analytics (ICBDA)*. ACM, 2021: 1245-1254. <https://doi.org/10.1145/3459637.3482348>.
- [16] LEE J, KIM R, YI S W, et al. MAPS: multi-agent reinforcement learning-based portfolio management system[A/OL]. *arXiv* (2020). <https://arxiv.org/abs/2007.05402>.
- [17] 唐国豪, 陈海玮, 朱琳, 等. 投资者预期协同的资产定价研究——基于多特征机器学习视角[J]. *管理世界*, 2025(12): 88-104.
- [18] LEMMON M, PORTNIAGUINA E. Consumer confidence and asset prices: some empirical evidence[J/OL]. *The Review of Financial Studies*, 2006, 19(4): 1499-1529. DOI: 10.1093/rfs/hhj038.
- [19] 朱宏泉, 余江, 陈林. 异质信念、卖空限制与股票收益——基于中国证券市场的分析[J]. *管理科学学报*, 2016, 19(7): 115-126.
- [20] 孟庆斌, 黄清华. 卖空机制是否降低了股价高估?——基于投资者异质信念的视角[J/OL]. *管理科学学报*, 2018, 21(4): 43-66. DOI: 10.3969/j.issn.1007-9807.2018.04.003.
- [21] DIETHER K B, MALLOY C J, SCHERBINA A. Differences of opinion and the cross section of stock returns[J/OL]. *The Journal of Finance*, 2002, 57(5): 2113-2141. DOI: 10.1111/1540-6261.00497.

- [22] ANDERSON E W, GHYSELS E, JUERGENS J L. Do heterogeneous beliefs matter for asset pricing?[J/OL]. The Review of Financial Studies, 2005, 18(3): 875-924. DOI: 10.1093/rfs/hhi017.
- [23] HORNIK K, STINCHCOMBE M, WHITE H. Multilayer feedforward networks are universal approximators[J]. Neural Networks, 1989, 2(5): 359-366.
- [24] SIMS C A. Implications of rational inattention[J]. Journal of Monetary Economics, 2003, 50(3): 665-690.
- [25] DANIEL K, HIRSHLEIFER D, SUBRAHMANYAM A. Investor psychology and security market under- and overreactions[J]. The Journal of Finance, 1998, 53(6): 1839-1885.
- [26] HONG H, STEIN J C. Disagreement and the stock market[J]. Journal of Economic Perspectives, 2007, 21(2): 109-128.
- [27] MILLER E M. Risk, uncertainty, and divergence of opinion[J/OL]. The Journal of Finance, 1977, 32(4): 1151-1168. DOI: 10.1111/j.1540-6261.1977.tb03317.x.
- [28] JOHNSON T C. Forecast dispersion and the cross section of expected returns [J/OL]. The Journal of Finance, 2004, 59(5): 1957-1978. DOI: 10.1111/j.1540-6261.2004.00691.x.
- [29] HENNING T, OJHA S M, SPOON R, et al. LLM agents do not replicate human market traders: evidence from experimental finance: arXiv:2502.15800[R/OL]. arxiv (2025). <https://arxiv.org/abs/2502.15800>. DOI: 10.48550/arXiv.2502.15800.
- [30] VIRATTT, CONTRIBUTORS. AI hedge fund: a multi-agent system for algorithmic trading[R/OL]. GitHub, 2025. <https://github.com/virattt/ai-hedge-fund>.
- [31] YANG Y, ZHANG Y, WU M, et al. TwinMarket: a scalable behavioral and social simulation for financial markets[C/OL]//NeurIPS: Vol. 39 The Thirty-ninth Annual Conference on Neural Information Processing Systems (NeurIPS). 2025. <https://arxiv.org/abs/2502.01506>. DOI: 10.48550/arXiv.2502.01506.

- [32] BAI Y, GAO Y, WAN R, et al. A review of reinforcement learning in financial applications[J/OL]. Annual Review of Statistics and Its Application, 2025, 12: 209-232. DOI: 10.1146/annurev-statistics-112723-034423.
- [33] QURESHI W, KADIA A, GOYAL A, et al. Deep learning vs. reinforcement learning in automated stock trading: a PRISMA-oriented systematic review[J/OL]. International Journal of Scientific and Advanced Technology (IJSAT), 2026, 17(1). DOI: 10.71079/IJSAT.2026.17101.
- [34] MARZBAN S, HASHEMI M, ZARE M, et al. WaveCorr: correlation-savvy deep reinforcement learning for portfolio management[A/OL]. arXiv (2021). <https://arxiv.org/abs/2109.07005>.
- [35] LIU X Y, YANG H, GAO J, et al. FinRL: deep reinforcement learning framework to automate trading in quantitative finance[A/OL]. arXiv (2021). <https://arxiv.org/abs/2111.09395>.
- [36] BALI T G, KELLY B T, MÖRKE M, et al. Machine forecast disagreement: w31583[Z]. National Bureau of Economic Research (NBER), 2023.
- [37] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [38] MOODY J E, WU L, LIAO Y, et al. Performance functions and reinforcement learning for trading systems and portfolios[J]. Journal of Forecasting, 1998, 17 (5-6): 441-466.
- [39] JIANG Z, XU D, LIANG J. A deep reinforcement learning framework for the financial portfolio management problem[A/OL]. arXiv (2017). <https://arxiv.org/abs/1706.10059>. DOI: 10.48550/arXiv.1706.10059.
- [40] MARKOWITZ H M. The optimization of a quadratic function subject to linear constraints[J/OL]. Naval Research Logistics Quarterly, 1956, 3(1-2): 111-133. DOI: 10.1002/nav.3800030110.
- [41] 尹海员, 李忠民. 个体特质、信息获取与风险态度——来自中国股民的调查分析[J]. 经济评论, 2011, 2: 29-37.

- [42] 张玥. 中国股市投资者风险厌恶系数测算研究[J]. 福建质量管理, 2019: 74-76,53.
- [43] JIANG L, NIU H, WANG H, et al. Dynamic implied risk aversion term structure: an empirical analysis based on shanghai stock exchange 50 ETF option[J/OL]. Mathematical Problems in Engineering, 2023, 2023: 9917375. DOI: 10.1155/2023/9917375.
- [44] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[A/OL]. arXiv (2017). <https://arxiv.org/abs/1707.06347>. DOI: 10.48550/arXiv.1707.06347.
- [45] RAFFIN A, HILL A, GLEAVE A, et al. Stable-Baselines3: reliable reinforcement learning implementations[J/OL]. Journal of Machine Learning Research, 2021, 22 (268): 1-8. <http://jmlr.org/papers/v22/20-1284.html>.
- [46] HONG H, SRAER D A. Speculative betas[J]. The Journal of Finance, 2016, 71 (5): 2095-2141.
- [47] BANERJEE S. Learning from prices and the dispersion in beliefs[J]. The Review of Financial Studies, 2011, 24(9): 3025-3068.

致谢

以简短的文字表达作者对完成论文和学业提供帮助的老师、同学、领导、同事及亲属的感激之情。

附录 A 因子说明

附录 B 系统设计

本研究涉及较长的数据周期，较多的 Agent 和数量庞大的因子数据，如果仅依赖单进程/本地数据，全量加载数据，需要极大的资源开销和运算时间。

为了解决训练问题，依照论文需要，设计了一个基于“数据流水线”和“分布式训练”的计算集群。

B.1 系统架构

整体计算集群的架构如图B.1所示。




图 B.1 系统架构

B.1.1 总体架构设计

本研究构建了一个分布式多 Agent 强化学习训练平台，用于大规模投资组合优化实验。系统采用主从分布式架构，由中央控制节点、代理节点集群和数据存储系统组成，如图 B.1所示。系统设计的核心思想是”数据流水线”与”分布式训练”的有机结合：数据流水线负责数据的预加载、清洗和缓存管理，确保训练过

程中数据的高效访问；分布式训练则通过容器化部署实现计算资源的弹性扩展和并行训练能力的提升。

B.1.2 中央控制节点

中央控制节点（Master）是整个系统的核心控制单元，承担着多重关键职能。它负责实验任务调度，根据实验配置生成训练任务，并采用负载均衡策略将任务分配给各个代理节点，确保计算资源的充分利用。同时，它还提供数据服务，维护数据库，为代理节点提供标准化后的特征数据。此外，中央节点还承担结果收集与分析的职能，进行性能统计、风险指标计算和可视化分析，支持实时监控训练进度和系统状态。最后，中央节点负责系统监控与容错，实时监控各节点的运行状态，自动检测并处理节点故障，确保系统的稳定性和可靠性。

B.1.3 系统组件

代理节点集群由多个 Docker 容器化的训练节点组成，每个节点独立运行强化学习训练任务。节点采用多进程架构，同时运行 TCP 监听进程、FRP 通信客户端和训练工作进程，通过 Docker 容器实现计算资源隔离。

系统数据采用层次化存储结构：其中，数据库负责存储因子数据、收益数据、证券信息等原始数据；而结果仓库负责接收节点回传的训练结果，用于后续的分析。

系统采用分层网络通信架构：使用 FRP 反向代理解决 NAT 穿透问题，建立稳定的通信隧道，实现节点与中央控制节点的通信。FRP（Fast Reverse Proxy）是一个开源的反向代理工具，可以通过访问公网服务器，通过建立通信隧道，将数据转发到内网服务器，实现 NAT 穿透。在建立通信隧道后，中央节点可以通过 TCP 协议，向训练节点发送启动、查询、停止控制信号；训练节点能够访问中央节点的 redis 缓存，获取标准化后的因子数据，使用 rsync 协议，向中央节点回传训练结果。

B.1.4 系统工作流程




图 B.2 工作流程

如图 B.2所示，系统的工作流程遵循标准化的执行步骤。首先是任务初始化阶段，中央节点根据实验配置生成任务参数，通过 FRP 隧道安全分发到各代理

节点。然后，中央节点启动数据流水线，不断加载训练数据，进行标准化处理，并保存到 redis 缓存中；节点启动后，不断获取 redis 缓存中的标准化因子数据，进行训练，并回传训练结果到中央节点。

B.2 数据流水线

数据流水线是中央系统的核心组件，采用事件驱动架构和 Redis 中间件，主要实现两个关键功能：**1)** 分批次数据加载，有效控制内存占用；**2)** 实现预加载机制，保证训练过程的数据连续供应，避免训练节点受阻塞。

B.2.1 消息流

数据流水线采用事件驱动的异步通信架构，通过消息总线实现各组件间的松耦合协作。其工作流程如图 B.3 所示。




图 B.3 数据流水线工作流程

其中，各个组件的具体功能为：

表 B.1 数据流水线核心组件功能说明

组件名称	功能描述
消息总线 (MessageBus)	系统的通信枢纽，采用发布-订阅模式协调各组件。支持异步事件路由，确保组件间的松耦合通信。
监控器 (Monitor)	系统的调度中枢，持续监控数据状态。维护数据片访问计数器，智能触发数据加载请求。执行双重监控：数量充足性和过期状态检查。
数据库读取器 (DBLoader)	数据获取组件，按时间窗口批量加载因子数据。执行数据格式转换，确保与后续处理环节的兼容性。
更新器 (Updater)	数据预处理组件，执行标准化和数据分片操作。将原始数据转换为适合训练的标准化数据片。通过访问节点管理器信息，准确判断数据片访问完成状态。
数据缓存层 (Cache)	Redis 实现的分布式缓存，存储标准化数据片和节点状态信息。提供高性能数据访问，支持并发读写操作。
节点管理器 (NodeManager)	虽然不直接参与消息流，但持续监控各训练节点的保活状态。将活跃节点信息存储到 Redis，为更新器提供节点状态查询服务，支持数据片过期判断。

数据流水线的工作流程采用标准化的消息驱动模式，具体执行步骤如下：

1. 数据监控阶段

监控器持续监控 Redis 缓存中的数据片状态，包括两个维度：

数量监控：检查数据片总数（年数）是否低于预设阈值，确保训练过程的数据供应连续性；

过期检查：通过访问计数器判断数据片是否被所有活跃节点访问完毕，过期数据片需要及时清理。

当检测到数据不足时，监控器向消息总线发布 *LoadRequest* 事件。

2. 数据加载阶段

消息总线接收 *LoadRequest* 事件，路由至数据库读取器。

数据库读取器从数据库加载指定时间窗口的因子数据，转换为 *DataFrame* 格式，

临时存储到 Redis，并向消息总线发布 *DataLoaded* 事件。

3. 数据处理阶段

消息总线接收 *DataLoaded* 事件，路由至更新器。

更新器将因子-下期收益对齐，连接。

然后，执行 Z-Score 标准化和缺失值处理，

最后，按”年:月:证券代码”格式分割为数据片，存储到 Redis 缓存层。

4. 数据消费阶段

训练节点从 Redis 缓存获取所需的数据片进行模型训练。

每次数据访问操作后，对应数据片的计数器中记录该节点 ID。

当所有活跃的训练节点完成对某个数据片的访问后，该数据片被自动清理。

5. 循环控制

系统返回步骤 1，继续监控数据片数量，

形成持续的数据供应循环，确保训练过程的连续性。

B.3 分布式训练

